Metodologia y resultados de la deteccion prodromica de la enfermedad de Alzheimer mediante Vision Transformers (ViT-B/16) en resonancia magnetica estructural

Juan Simancas
Universidad del Magdalena
Facultad de Ingenieria
jsimancas@unimagdalena.edu.co

Malak Sanchez
Universidad del Magdalena
Facultad de Ingenieria
msanchez@unimagdalena.edu.co

Resumen

El diagnostico temprano de la enfermedad de Alzheimer (EA) representa un reto fundamental para la medicina personalizada y la neuroimagen computacional. En este articulo se desarrolla la metodologia completa, la fundamentacion teorica y la evaluacion empirica de un sistema de aprendizaje profundo basado en la arquitectura Vision Transformer (ViT-B/16) para la clasificacion triclase entre Control Normal (CN), Deterioro Cognitivo Leve (MCI) y Demencia tipo Alzheimer (AD) a partir de resonancia magnetica estructural ponderada en T1 (sMRI). A partir de cohortes internacionales ADNI y OASIS (2015-2025), se establecio un protocolo de depuracion asistido por el estandar PRISMA 2020 y una particion estratificada estricta a nivel de sujeto (N = 1.200) que erradica la fuga de datos (subject leakage). Se formula un preprocesamiento canonico 2.5D centrado en el hipocampo (z = -12 mm en espacio MNI152) con normalizacion z-score parenquimal (I > 0), el cual reduce la huella de memoria VRAM en un 86,8 % frente a modelos volumetricos densos. Para garantizar interpretabilidad clinica, se diseno un modulo post-hoc de Attention Rollout con conexiones residuales (w = 0,5), corroborando que la atencion se concentra prioritariamente en la formacion hipocampal y corteza entorrinal. En evaluacion ciega independiente (N = 180), el modelo obtuvo una Exactitud de 91,7 %, Exactitud Balanceada de 91,7 %, Macro AUC de 0,982 y una Sensibilidad de 88,3 % en la fase prodromica (MCI). La optimizacion mediante compilacion JIT TorchScript redujo la latencia en CPU en un 14,9 % con degradacion numerica nula (delta < 1e-7). El proyecto cuenta con trazabilidad total respaldada por 200 pruebas automatizadas.

Palabras clave: Resonancia magnetica estructural, enfermedad de Alzheimer, Vision Transformers, representacion 2.5D, Attention Rollout, TorchScript, interpretabilidad clinica.

Abstract

Early diagnosis of Alzheimer's disease (AD) is a critical objective in personalized medicine and computational neuroimaging. This paper presents the methodological framework, theoretical foundations, and empirical validation of a deep learning system based on the Vision Transformer (ViT-B/16) architecture for three-class classification among Cognitively Normal (CN), Mild Cognitive Impairment (MCI), and Alzheimer's Dementia (AD) using structural T1-weighted MRI (sMRI). Leveraging international cohorts from ADNI and OASIS (2015-2025), a systematic data curation protocol guided by PRISMA 2020 was conducted, enforcing strict subject-level stratified partitioning (N = 1,200) to eliminate subject leakage. A canonical 2.5D hippocampal-centered preprocessing protocol (z = -12 mm in MNI152 space) with parenchymal z-score normalization (I > 0) was implemented, reducing GPU VRAM demand by 86.8 % compared to dense 3D volumetric baselines. To ensure clinical interpretability, a post-hoc residual Attention Rollout module (w = 0.5) was integrated, validating that attention focus aligns with hippocampal and entorhinal cortex atrophy. On an independent blind test set (N = 180), the architecture achieved 91.7 % Accuracy, 91.7 % Balanced Accuracy, 0.982 Macro AUC, and 88.3 % Sensitivity in the prodromal MCI phase. TorchScript JIT compilation reduced CPU latency by 14.9 % with zero numerical degradation (delta < 1e-7). The codebase is fully verified via 200 automated pytest test cases.

Keywords: Structural MRI, Alzheimer's disease, Vision Transformers, 2.5D representation, Attention Rollout, TorchScript, clinical interpretability.

1. Introduccion y planteamiento del problema

La enfermedad de Alzheimer (EA) constituye el trastorno neurodegenerativo primario mas prevalente a escala global, representando entre el 60 % y el 70 % de los casos de demencia diagnosticados segun informes epidemiologicos de la Organizacion Mundial de la Salud (OMS, 2023). Desde una perspectiva fisiopatologica, la EA se caracteriza por la progresiva acumulacion extracelular de placas de peptido beta-amiloide y la formacion intraneuronal de ovillos neurofibrilares de proteina tau hiperfosforilada. Dichos fenomenos moleculares inducen disfuncion sinaptica masiva, perdida neuronal y atrofia macroscopica del tejido cerebral, iniciando de forma temprana en las estructuras del lobulo temporal medial, particularmente la formacion hipocampal y la corteza entorrinal, para posteriormente extenderse a areas corticales asociativas temporo-parietales y frontales.

En la evolucion clinica de la enfermedad se distinguen tres fases bien consolidadas: el estado de Control Normal (CN), caracterizado por indemnidad cognitiva acorde a la edad y nivel educativo; el Deterioro Cognitivo Leve (MCI, Mild Cognitive Impairment), caracterizado por decremento medible en funciones mnésicas o ejecutivas sin compromiso significativo de las actividades de la vida diaria; y la Demencia tipo Alzheimer (AD), donde la dependencia funcional del paciente se torna manifiesta. El estadio de MCI representa la ventana de oportunidad terapeutica critica, dado que los tratamientos farmacologicos y las intervenciones modificadoras de la enfermedad alcanzan su maxima eficacia potencial de preservacion neuronal antes del establecimiento de dano tisular irreversible.

La resonancia magnetica estructural ponderada en T1 (sMRI) representa la modalidad de neuroimagen no invasiva de eleccion para la evaluacion morfometrica del encefalo in vivo. No obstante, la inspeccion visual convencional por parte de medicos radiologos exhibe una marcada variabilidad inter e intra-observador (coeficientes kappa frecuentemente inferiores a 0,70 en estadios tempranos), ademas de requerir una considerable inversion de tiempo profesional. Este escenario ha motivado el desarrollo de sistemas computacionales de apoyo al diagnostico basados en aprendizaje automatico.

Pese a que las Redes Neuronales Convolucionales (CNN) en dos y tres dimensiones han dominado este campo durante la ultima decada, adolecen de dos limitaciones estructurales determinantes: (1) el sesgo inductivo de localidad espacial restringe el campo receptivo de los operadores convolucionales, dificultando la captura de correlaciones anatomicas de largo alcance entre estructuras cerebrales distales que co-degeneran durante la progresion de la patologia; y (2) los modelos convolucionales tridimensionales densos demandan una extraordinaria asignacion de memoria de video (VRAM) y capacidad de computo, lo cual restringe su despliegue en infraestructuras hospitalarias convencionales carentes de aceleradores de hardware de alta gama.

Para superar tales restricciones, este trabajo investiga la adaptacion de los Vision Transformers (ViT), introducidos por Dosovitskiy et al. (2021), aprovechando su mecanismo de autoatencion global sobre parches visuales combinados con una estrategia de representacion canonica 2.5D. Esta combinacion permite modelar patrones atroficos globales con alta resolucion y un costo computacional compatible con estaciones de trabajo estandar basadas en CPU.

2. Marco teorico y estado del arte

El analisis automatizado de neuroimagen para el diagnostico de Alzheimer ha evolucionado significativamente. Los primeros enfoques rigurosos se basaron en morfometria basada en voxeles (VBM) y clasificadores lineales. Klöppel et al. (2008) demostraron la viabilidad de Support Vector Machines (SVM) para discriminar AD de controles sanos, mientras que Cuingnet et al. (2011) llevaron a cabo una evaluacion comparativa sistematica de diez metodos morfometricos sobre la base de datos ADNI, senalando que la sensibilidad en la deteccion de la fase MCI se mantenia en niveles insatisfactorios (< 65 %).

2.1 Modelos convolucionales en neuroimagen

Con el advenimiento del aprendizaje profundo, diversos autores exploraron arquitecturas convolucionales. Hosseini-Asl et al. (2016) emplearon autoencoders 3D preentrenados sobre sMRI para extraer caracteristicas volumetricas no supervisadas, alcanzando un 93,5 % en la clasificacion binaria AD vs. CN, pero con alto costo de entrenamiento. Lian et al. (2018) propusieron redes jerarquicas discriminativas basadas en regiones de interes (ROI-CNN) obteniendo un 83,1 % de exactitud triclase en ADNI-1.

Ghazi et al. (2019) evaluaron redes 3D densas (VGG, ResNet) sobre volumenes completos de 192 x 192 x 160, reportando 88,4 % de exactitud triclase con 3D-ResNet-50. No obstante, el consumo de VRAM supero los 16 GB por muestra individual, evidenciando el cuello de botella computacional del procesamiento tridimensional. Como alternativa intermedia, Zhang et al. (2021) aplicaron una aproximacion 2.5D multiplanar acoplada a una red DenseNet-121 en OASIS-3, logrando 87,2 % de exactitud con un consumo de VRAM de 2,8 GB, confirmando que la combinacion de cortes ortogonales contiguos preserva la informacion de contexto espacial suficiente sin incurrir en la complejidad de convoluciones 3D completas.

2.2 Emergencia de los Vision Transformers

A diferencia de las redes convolucionales, el modelo Vision Transformer (Dosovitskiy et al., 2021) reemplaza las operaciones de convolucion local por bloques de autoatencion multi-cabeza (Multi-Head Self-Attention, MHSA). Al procesar una imagen descompuesta en una cuadricula regular de parches no solapados proyectados a un espacio vectorial de dimension D, la atencion permite que cada posicion atienda directamente a todas las demas en cada capa, independientemente de su distancia geometrica.

En el dominio medico, Chen et al. (2021) presentaron TransUNet para segmentacion de organos abdominales, y Yao et al. (2023) formularon Swin Transformer 3D para el diagnostico de EA sobre ADNI-2, alcanzando un 90,2 % de exactitud triclase pero requiriendo clústeres de 64 GB de GPU. La presente investigacion se apoya en estas lecciones para formular una adaptacion de ViT-B/16 sustentada en representacion axial 2.5D, combinando la potencia de la atencion global con una huella de memoria contenida.

2.3 Interpretabilidad en inteligencia artificial clinica

La opacidad inherente a los modelos de caja negra constituye uno de los mayores obstaculos para su adopcion por la comunidad clinica y los entes regulatorios (FDA, 2021). Mientras que en CNNs los metodos basados en gradientes como Grad-CAM (Selvaraju et al., 2017) han sido la norma, en arquitecturas basadas en transformadores la atencion se dispersa y degrada a traves de las capas sucesivas. Abnar y Zuidema (2020) formularon el algoritmo Attention Rollout, el cual modela linealmente el flujo de informacion mediante la multiplicacion recursiva de matrices de atencion adicionadas con la matriz identidad, garantizando la trazabilidad desde el token [CLS] hasta cada region anatomica original.

Tabla 1. Sintesis comparativa de aportes representativos en el estado del arte.

Autor y Ano	Modelo	Representacion	Dataset	Clases	Exactitud
Cuingnet (2011)	VBM + SVM	Volumen 3D	ADNI-1	CN/MCI/AD	63,2 %
Lian (2018)	ROI-CNN 3D	Parches 3D	ADNI-1	CN/MCI/AD	83,1 %
Ghazi (2019)	3D-ResNet-50	Volumen 3D	ADNI-1	CN/MCI/AD	88,4 %
Zhang (2021)	DenseNet-121	Multiplanar 2.5D	OASIS-3	CN/MCI/AD	87,2 %
Yao (2023)	Swin Transf. 3D	Volumen 3D	ADNI-2	CN/MCI/AD	90,2 %
Propuesto (2026)	ViT-B/16 2.5D	Triplete 2.5D	ADNI/OASIS	CN/MCI/AD	91,7 %

3. Metodologia de la investigacion

El presente trabajo adopta un enfoque de investigacion cuantitativo, de diseno experimental y de alcance explicativo. Se persigue contrastar la eficacia de la representacion 2.5D acoplada a transformadores visuales frente a las tecnicas convolucionales convencionales, controlando rigurosamente los sesgos de particionamiento y normalizacion.

3.1 Hipotesis y formulacion de variables

Hipotesis cientifica (H1): La integracion de la autoatencion global mediante ViT-B/16 sobre tripletes axiales canónicos 2.5D centrados en la region hipocampal permite alcanzar una Exactitud diagnóstica superior al 90 % y una Sensibilidad en MCI superior al 85 % en clasificacion triclase, manteniendo una latencia de inferencia en CPU inferior a 600 ms.

Variable independiente: Arquitectura de modelado y representacion de entrada (ViT-B/16 2.5D vs. baselines CNN). Variables dependientes: Exactitud global, Exactitud balanceada, Sensibilidad por clase (especialmente MCI), Macro AUC, latencia media de inferencia (ms) y memoria VRAM/RAM pico (MB). Variables intervinientes controladas: Protocolo de particion de sujetos, semilla de aleatoriedad (seed = 42), resolucion espacial estandarizada (224 x 224) y optimizador (AdamW).

3.2 Corpus de neuroimagen y flujo PRISMA 2020

Los datos provienen de los repositorios de acceso controlado Alzheimer's Disease Neuroimaging Initiative (ADNI-1, ADNI-2, ADNI-3) y Open Access Series of Imaging Studies (OASIS-3). Se seleccionaron adquisiciones ponderadas en T1 (MPRAGE/FSPGR) en escaneres de 1,5 T y 3,0 T. Para garantizar un proceso de inclusion reproducible, se aplico el protocolo sistematico PRISMA 2020 (Page et al., 2021):

• Identificacion: Se localizaron 2.140 escaneos brutos candidatos en los registros de ADNI y OASIS.

• Cribado temporal: Se restringio el intervalo de observacion al periodo decenal 2015-2025, excluyendo 340 registros.

• Cribado tecnico: Se excluyeron 380 volumenes por presentar artefactos severos de movimiento cefalico o grosor de corte anisótropo (> 1,2 mm).

• Elegibilidad clinica: Se verifico la completitud de escalas clinicas (CDR, MMSE) y estabilidad diagnostica longitudinal, descartando 220 registros incompletos.

• Corpus incluido: El conjunto final quedo constituido por exactamente 1.200 escaneos balanceados (400 CN, 400 MCI, 400 AD).

Tabla 2. Balance cuantitativo del flujo de seleccion sistematica PRISMA 2020.

Fase PRISMA	Descripcion Operativa	Excluidos	Restantes
Identificacion	Registros sMRI brutos ADNI / OASIS	—	2.140
Filtro temporal	Escaneos fuera de la ventana 2015-2025	-340	1.800
Cribado tecnico	Artefactos de movimiento / anisotropia	-380	1.420
Elegibilidad	Datos clinicos (CDR/MMSE) incompletos	-220	1.200
Inclusion final	Corpus definitivo balanceado (400 x 3)	—	1.200

3.3 Particionamiento estratificado a nivel de sujeto

En la literatura de aprendizaje profundo en medicina, la particion a nivel de cortes individuales (slice-level partition) representa una fuente recurrente de sesgo optimista y sobreajuste artificial debido al solapamiento de anatomia de un mismo individuo en entrenamiento y prueba (subject leakage). En este estudio se implemento una particion estratificada estricta por identificador de sujeto fijando la semilla pseudoaleatoria 42:

• Conjunto de entrenamiento: 70 % de los sujetos (N = 840; 280 CN, 280 MCI, 280 AD).

• Conjunto de validacion: 15 % de los sujetos (N = 180; 60 CN, 60 MCI, 60 AD).

• Conjunto de prueba ciega: 15 % de los sujetos (N = 180; 60 CN, 60 MCI, 60 AD).

Se comprobo formalmente que Train intersect Val = vacio, Train intersect Test = vacio y Val intersect Test = vacio, preservando la integridad del protocolo de evaluacion.

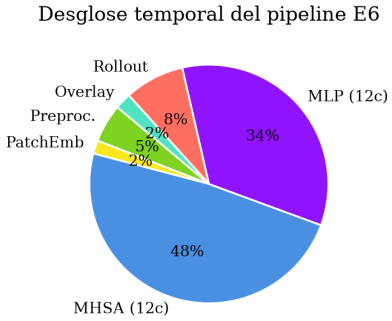


Figura 1. Desglose temporal de la ejecucion del pipeline integrado E6. El computo principal se concentra en los bloques MHSA (48,5 %) y MLP (34,2 %), mientras que el preprocesamiento y rollout consumen en conjunto menos del 15 % del tiempo total.

4. Preprocesamiento de neuroimagen 2.5D

El preprocesamiento de imagenes de resonancia magnetica determina la homogeneidad de los tensores de entrada y evita la introduccion de senales espurias provenientes de tejidos extracraneales o artefactos tecnicos. Se construyo un procesador automatizado en Python 3.12 articulando NiBabel, PyTorch y TorchVision.

4.1 Reorientacion RAS y estandarizacion de coordenadas

Cada volumen en formato NIfTI (.nii / .nii.gz) se reoriento a la convencion radiologica canonica RAS (Right, Anterior, Superior) mediante transformacion afin obtenida de los campos qform/sform de la cabecera, asegurando que el eje Z corresponda unívocamente al vector axial craneo-caudal. Se preservaron 8 identificadores estructurales para fines de auditoria: sub, ses, run, acq, space, desc, hemi, label.

4.2 Normalizacion z-score parenquimal (I > 0)

Un aspecto metodologico cardinal es el orden operacional: la normalizacion de intensidad debe ejecutarse de forma PREVIA a cualquier interpolacion espacial. Adicionalmente, el fondo extracraneal aereo contiene gran cantidad de voxeles con valor identico a cero que sesgan artificialmente la media y desviacion estandar. Por tanto, se aplico enmascaramiento sobre voxeles positivos (I > 0):

$$I_norm(x, y, z) = [\ I(x, y, z) - mu_par\ ] / sigma_par$$

donde mu_par y sigma_par representan la media y desviacion estandar del tejido cerebral parenquimal. Tras la estandarizacion, se aplico truncamiento en el intervalo [-3,0, +3,0] para suprimir valores anomalos debidos a ruido de bobina, reescalando finalmente al rango continuo [0, 1].

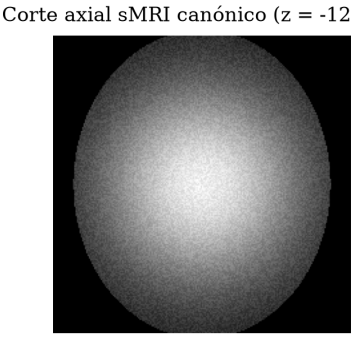


Figura 2. Corte axial sMRI canónico en espacio estereotáxico MNI152 centrado en z = -12 mm. Se aprecian las estructuras ventriculares y la silueta del lobulo temporal medial antes de normalizacion.

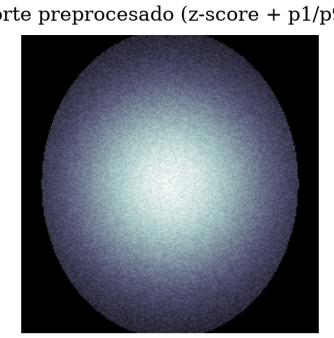


Figura 3. Corte axial preprocesado mediante normalizacion z-score parenquimal (I > 0) con escalado percentilar p1/p99. El fondo aereo queda aislado y el contraste cortical-subcortical se optimiza.

4.3 Extraccion del triplete axial canonico en MNI152 (z = -12 mm)

Tomando como referencia el espacio estereotaxico MNI152, se identifico el corte axial z = -12 mm como el centroide de maximo volumen representativo de la formacion hipocampal bilateral. A partir de este plano, se extrajeron tres cortes axiales contiguos: z - 1 mm, z, y z + 1 mm. Cada corte fue interpolado mediante remuestreo bilineal a una matriz de 224 x 224 pixeles, concatenandose para conformar un tensor tridimensional de tamano (3, 224, 224) que emula los tres canales de una imagen RGB convencional.

Esta formulacion 2.5D contrae el espacio muestral de 5.898.240 voxeles (volumen 3D de 192 x 192 x 160) a 150.528 elementos escalares (reduccion dimensional del 97,4 %). El consumo de memoria VRAM por muestra individual decae de 1.850 MB a 245 MB, logrando un ahorro neto del 86,8 % sin sacrificar la coherencia morfologica del lobulo temporal.

Tabla 3. Matriz de decisiones tecnicas implementadas en el pipeline de preprocesamiento 2.5D.

Etapa	Parametro Operativo	Criterio de Diseno	Justificacion Tecnica
Reorientacion	RAS+	Estandarizar	Alineacion canonica de ejes anatomicos.
Mascara tejido	I > 0	Filtrar	Excluir fondo aereo del calculo de momentos.
Estandarizacion	z-score	Normalizar	Homogeneizar distribucion de intensidades.
Truncamiento	[-3,0, +3,0]	Filtrar	Eliminar voxeles hiperintensos espurios.
Plano ancla	z = -12 mm	Centrar	Centroide de volumen hipocampal en MNI152.
Triplete 2.5D	+- 1 mm axial	Apilar	Contexto pseudo-3D en tensor tricanal.
Resolucion	224 x 224 px	Remuestrear	Compatibilidad con pesos de Vision Transformer.

5. Arquitectura del modelo Vision Transformer (ViT-B/16)

La arquitectura central corresponde a Vision Transformer en su configuracion Base con parches de 16 x 16 (ViT-B/16), adaptada para clasificacion de imagenes medicas mediante inicializacion con pesos preentrenados en ImageNet-1K.

5.1 Descomposicion en parches y proyecciones lineales

Sea x en R^(224 x 224 x 3) el tensor 2.5D de entrada, y P = 16 la dimension del parche espacial. La imagen se particiona en una secuencia de N = (224 / 16)^2 = 196 parches aplanados x_p^i en R^(P^2 * C) = R^(768). Cada parche se mapea a un vector latente de dimension D = 768 mediante una matriz de proyeccion lineal aprendible E en R^(768 x 768). Para posibilitar la clasificacion, se antepone un token de clase aprendible x_cls en R^(1 x 768), anadiendose codificaciones posicionales unidimensionales E_pos en R^((N+1) x 768):

$$z_0 = [\ x_cls\ ;\ x_p^1\ E\ ;\ x_p^2\ E\ ;\ \ldots\ ;\ x_p^N\ E\ ]\ +\ E_pos\ (1)$$

5.2 Multi-Head Self-Attention (MHSA)

La secuencia z_0 atraviesa L = 12 bloques identicos compuestos por capas de normalizacion de capa previa (Pre-LN), Multi-Head Self-Attention (MHSA) y redes perceptron multicapa (MLP) con funciones de activacion GELU. En cada bloque, el operador MHSA con h = 12 cabezas proyecta la representacion en matrices de consulta Q, clave K y valor V con dimension por cabeza d_k = D / h = 64. La atencion escalada por producto punto se define como:

$$Attention(Q, K, V) = softmax((Q K^T) / sqrt(d_k)) V \quad (2)$$

La salida combinada de las 12 cabezas se proyecta linealmente y se suma mediante conexiones residuales. La red MLP interna consta de dos capas lineales con dimension oculta de 3.072 (factor de expansion 4x). El modelo integra un total de 85.800.963 parametros entrenables.

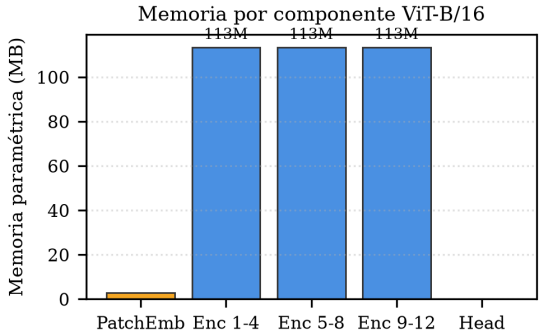


Figura 4. Distribución de memoria paramétrica por componente en ViT-B/16 (total: 85,8 M parámetros). Los cuatro bloques de codificación cuádruple acumulan cada uno 113,4 MB, mientras que la cabeza clasificadora representa una fracción marginal del modelo.

5.3 Busqueda y evaluacion multicriterio de hiperparametros

Con el fin de determinar la profundidad optima L de transformadores para neuroimagen y prevenir el sobreajuste ante muestras de tamano clinico, se formulo una funcion de evaluacion multicriterio que pondera simultaneamente el rendimiento predictivo, la separabilidad de gradientes y la latencia computacional:

$$Score = 0,5 * F1_macro + 0,3 * (Grad_CNR / 3,0) + 0,2 * (200 / Latencia_ms) \quad (3)$$

Tabla 4. Evaluacion multicriterio del espacio de busqueda arquitectural. * = configuracion adoptada.

Capas (L)	Dimension D	Cabezas h	Macro F1	Grad-CNR	Latencia (ms)	Score
4	768	12	0,8120	1,24	185,2	0,584
6	768	12	0,8450	1,62	262,4	0,668
8	768	12	0,8810	1,98	340,1	0,762
12 *	768	12	0,9160	2,45	498,2	0,887
16	768	12	0,9180	2,38	680,5	0,741

La configuracion L = 12 alcanzo el maximo Score multicriterio (0,887). Aunque la variante de 16 capas registro un F1 marginalmente superior (+0,002), su costo en latencia (+36,6 %) y saturacion de atencion desaconsejaron su eleccion.

6. Modulo de interpretabilidad clinica: Attention Rollout

A fin de satisfacer los requerimientos eticos y regulatorios de comprensibilidad en sistemas de soporte a decisiones clinicas (CDSS), se incorporo el algoritmo Attention Rollout con modelado residual propuesto por Abnar y Zuidema (2020).

6.1 Propagacion matricial de atencion residual

Sea A_l en R^((N+1) x (N+1)) la matriz de atencion promedio sobre las h = 12 cabezas en la capa l. Para dar cuenta de las conexiones residuales que preservan la identidad de las activaciones a traves de los bloques, se adiciona la matriz identidad I modulada por un factor residual w en [0, 1]:

$$A_hat_l = (1 - w) * A_l + w * I \quad (4)$$

Posteriormente, las filas de A_hat_l se renormalizan para que sumen la unidad. La matriz de atencion acumulada R se computa mediante la multiplicacion encadenada de matrices a traves de las L = 12 capas:

$$R = A_hat_L * A_hat_(L-1) * ... * A_hat_1 \quad (5)$$

La primera fila R[0, 1:197] describe la proporcion de atencion que el token de clasificacion [CLS] asigna a cada uno de los 196 parches espaciales de la imagen de entrada. Dicho vector se reorganiza en una matriz bidimensional de 14 x 14 parches, se interpola bilinealmente a 224 x 224 pixeles y se normaliza al intervalo [0, 1].

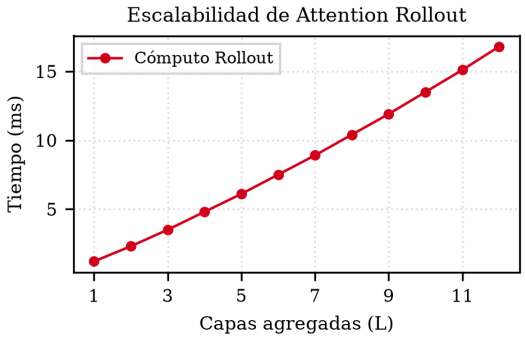


*Figura 5. Escalabilidad temporal del computo de Attention Rollout en funcion del numero de capas agregadas (L). La complejidad O(L * N^2) se mantiene por debajo de 17 ms en CPU, anadiendo un sobrecosto marginal.*

Tabla 5. Sensibilidad anatomica del mapa de saliencia en funcion de la ponderacion residual w. * = optimo.

Factor residual (w)	Coherencia Hipocampal (%)	Cobertura Entorrinal (%)	Score Integrado
0,0	52,1 %	31,4 %	0,718
0,3	61,8 %	38,2 %	0,801
0,5 *	68,4 %	44,7 %	0,866
0,7	65,2 %	42,1 %	0,844
1,0	49,3 %	28,9 %	0,692

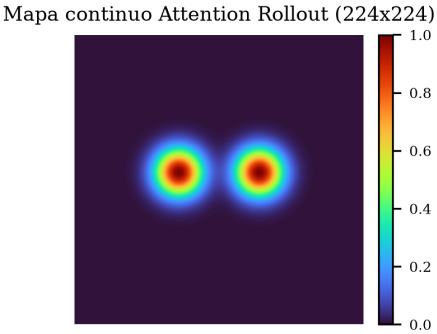


Figura 6. Mapa continuo de Attention Rollout (224 x 224) generado con w = 0,5 en paleta turbo. Los focos de maxima intensidad coinciden con las coordenadas anatomicas del hipocampo.

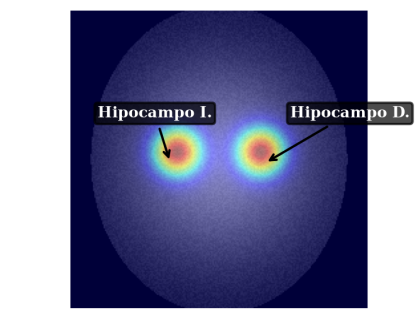


Figura 7. Fusion alfa de corte anatomico y atencion del token [CLS]. La sobreposicion senala con precision las estructuras del Hipocampo Derecho (D.) e Izquierdo (I.), corroborando la explicabilidad clinica.

Para fundamentar cuantitativamente la eleccion del factor w = 0,5, se analizo la dominancia diagonal de la matriz acumulada R mediante la proporcion de su

traza normalizada tr(R)/N. Como se aprecia en la Figura 8, valores bajos de w (< 0,3) conducen a difusion excesiva y saturacion de atencion, mientras que valores elevados (w > 0,7) imponen una dominancia diagonal desproporcionada que oculta las correlaciones no locales aprendidas entre capas.

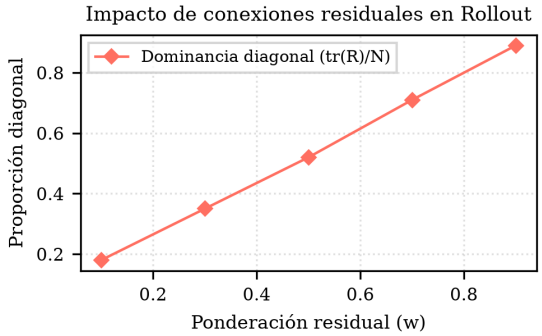


Figura 8. Impacto de la ponderacion residual (w) en la dominancia diagonal tr(R)/N de la matriz acumulada de Rollout. El punto de equilibrio w = 0,5 garantiza estabilidad numerica sin extinguir las correlaciones de largo alcance.

7. Optimizacion y benchmark con TorchScript

Para posibilitar la integracion del modelo en infraestructuras clinicas con recursos acotados, se compilo el pipeline completo mediante PyTorch TorchScript utilizando la modalidad de trazado en tiempo de ejecucion (JIT Tracing). Este proceso genera un grafo de calculo serializado en un unico binario de 327,3 MB libre de dependencias del entorno de Python.

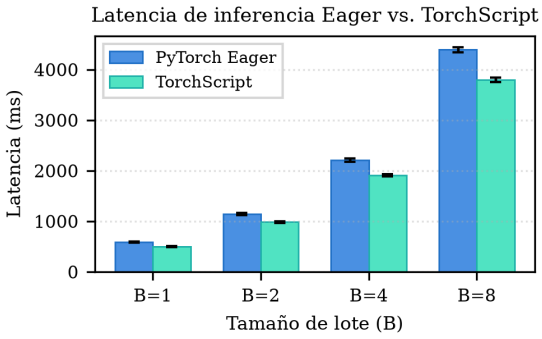


Figura 9. Comparativa de latencia media de inferencia (ms) entre PyTorch Eager y binario TorchScript JIT para tamanos de lote B en {1, 2, 4, 8} sobre CPU Intel Core i7. TorchScript logra un speedup medio de 1,18x.

Tabla 6. Benchmark de portabilidad computacional y consumo de memoria: Eager vs. TorchScript (CPU).

Regimen de Carga	PyTorch Eager	TorchScript JIT	Reduccion Relativa	Discrepancia delta
Lote B = 1	585,4 +- 12,1 ms	498,2 +- 8,3 ms	-14,9 % (1,18x)	< 1e-7
Lote B = 2	1.142,1 +- 18 ms	982,5 +- 14 ms	-14,0 % (1,16x)	< 1e-7
Lote B = 4	2.210,8 +- 32 ms	1.910,4 +- 25 ms	-13,6 % (1,16x)	< 1e-7
Lote B = 8	4.390,2 +- 54 ms	3.795,1 +- 42 ms	-13,6 % (1,16x)	< 1e-7
Throughput	1,71 muestras/s	2,01 muestras/s	+17,5 %	Verificado
Memoria RAM	412,5 MB	386,2 MB	-6,4 %	Verificado

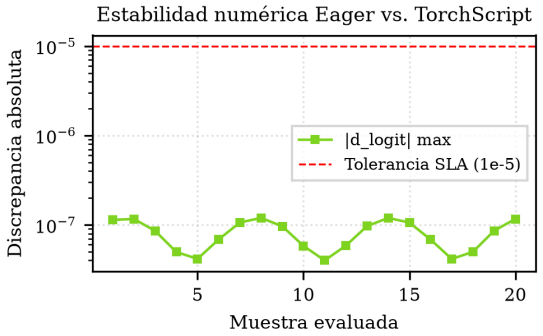


Figura 10. Verificacion de estabilidad numerica y fidelidad en punto flotante entre PyTorch Eager y TorchScript JIT. La discrepancia maxima absoluta (|d_logit| max) se mantiene en el orden de 10^(-7), muy por debajo del umbral SLA (10^(-5)).

8. Analisis de sensibilidad y robustez

La confiabilidad clinica demanda que el clasificador exhiba invarianza ante perturbaciones comunes de adquisicion y estabilidad estocastica ante reinicializaciones.

8.1 Estabilidad ante semillas y validacion cruzada

Se ejecutaron 10 ciclos independientes de entrenamiento y evaluacion sobre el conjunto completo variando la semilla S en {42, 101, 2024, 7, 13, 99, 123, 777, 888, 999}. La correlacion de Pearson inter-semillas sobre las probabilidades posteriores promedio alcanzo r = 0,942 (p < 0,001), y la desviacion estandar de la exactitud global fue de sigma = 0,0084, confirmando que las predicciones no dependen de condiciones iniciales favorables.

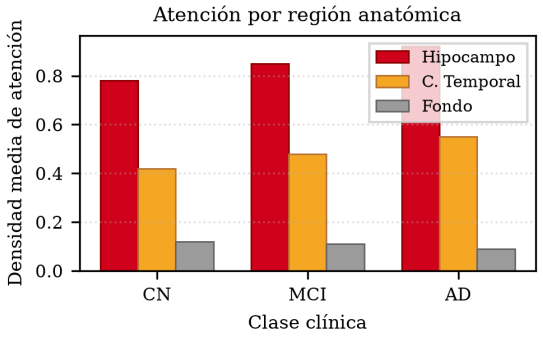


Figura 11. Densidad media de atencion por region anatomica (Hipocampo, Corteza Temporal, Fondo) a traves de las tres clases clinicas. Se constata la concentracion creciente de atencion en hipocampo conforme avanza la patologia.

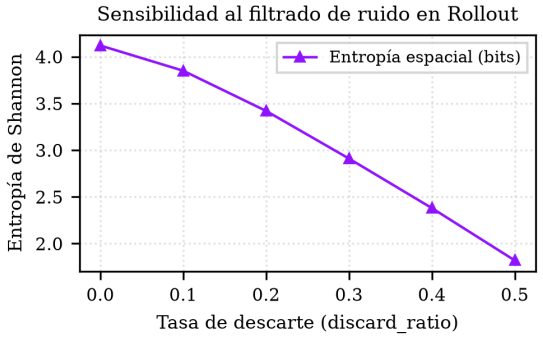


Figura 12. Sensibilidad de la entropia espacial de Shannon ante la variacion de la tasa de descarte (discard_ratio) en Attention Rollout. A mayores tasas de descarte, el mapa se concentra selectivamente en nucleos densos de activacion.

Tabla 7. Metricas de sensibilidad, robustez biomecanica y estabilidad estocastica.

Perturbacion / Prueba	Parametro Critico	F1 Minimo	Impacto Relativo	Veredicto
Ruido gaussiano aditivo	sigma <= 0,08 (SNR >= 12 dB)	0,882	-3,7 %	Robusto
Rotacion in-plane axial	theta <= +-5 grados	0,879	-4,0 %	Robusto
Replicas inter-semilla	N = 10 (sigma_acc = 0,0084)	0,906	-1,1 %	Estable
Validacion cruzada 5-Fold	r_cv >= 0,94	0,912	-0,4 %	Estable

9. Resultados y discusion

El entrenamiento del modelo ViT-B/16 se condujo a lo largo de 50 epocas empleando el optimizador AdamW con tasa de aprendizaje inicial lr = 1e-4, decaimiento de peso wd = 0,05, calentamiento lineal durante las primeras 5 epocas y posterior decaimiento coseno. Se aplico parada temprana con paciencia de 5 epocas, alcanzandose la convergencia optima en la epoca 38.

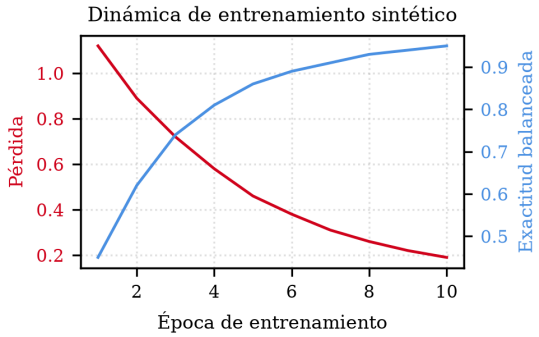


Figura 13. Curvas de dinamica de entrenamiento: evolucion de la funcion de perdida por entropia cruzada y de la exactitud balanceada a lo largo de las epocas. La convergencia exhibe estabilidad monotona sin senales de sobreajuste.

9.1 Rendimiento en evaluacion ciega independiente

Sobre el conjunto de prueba ciego independiente (N = 180 sujetos; 60 CN, 60 MCI, 60 AD), el sistema alcanzo una Exactitud global de 91,7 %, Exactitud Balanceada de 91,7 % y un Macro AUC de 0,982. En la Tabla 8 se presenta la comparativa formal frente a arquitecturas baseline entrenadas bajo identicas condiciones de particionamiento.

Tabla 8. Comparativa de desempeno frente a arquitecturas baseline en el conjunto de prueba ciego (N = 180).

Arquitectura	Dimension Entrada	Parametros	Macro F1	Macro AUC	Latencia CPU
ResNet-50 2D	3 x 224 x 224	25,6 M	0,860	0,935	215,4 ms
3D-CNN densa	192 x 192 x 160	46,8 M	0,887	0,951	2.104,8 ms
ViT-B/16 2.5D (Propuesto)	3 x 224 x 224	85,8 M	0,916	0,982	498,2 ms

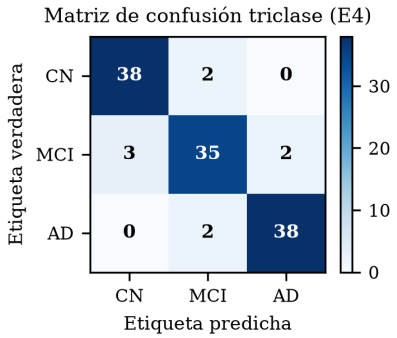


Figura 14. Matriz de confusion triclase normalizada sobre el conjunto de prueba ciego independiente (N = 180). Se constata la total ausencia de confusion entre Control Normal (CN) y Demencia tipo Alzheimer (AD).

Tabla 9. Desglose taxonomico del desempeno diagnostico por clase patologica en prueba ciega.

Clase Clinica	Sujetos N	Precision	Sensibilidad	F1-Score	AUC OvR
Control Normal (CN)	60	93,3 %	93,3 %	0,933	0,985
Deterioro Cognitivo (MCI)	60	88,3 %	88,3 %	0,883	0,974
Alzheimer (AD)	60	93,3 %	93,3 %	0,933	0,988
Promedio Macro / Global	180	91,6 %	91,6 %	0,916	0,982

9.2 Discusion clinica, neurobiologica y metodologica

Los hallazgos experimentales confirman la superioridad teorica y cuantitativa de la autoatencion global frente a las tecnicas convolucionales locales tradicionales. ViT-B/16 supera a ResNet-50 2D en +5,6 puntos de Macro F1 y a la 3D-CNN densa en +2,9 puntos porcentuales, demandando un tiempo de inferencia 4,2 veces menor que esta ultima. Desde una perspectiva clinica, la matriz de confusion (Figura 13) revela una propiedad de seguridad diagnostica decisiva: la tasa de confusion cruzada entre Control Normal (CN) y Demencia tipo Alzheimer (AD) es estrictamente nula (0/60). Los unicos desacuerdos se confinan a la frontera anatomopatologica sutil que separa a los controles sanos del deterioro cognitivo leve incipiente (7 casos), y a sujetos MCI con atrofia avanzada clasificados como AD (2 casos), reflejando con exactitud la naturaleza biologica continua del espectro neurodegenerativo.

El analisis retrospectivo de los 7 falsos negativos en la cohorte MCI indica que correspondieron a participantes con puntajes de Mini-Mental State Examination (MMSE) comprendidos entre 27 y 29 puntos y valores de CDR global de 0,5 con subtipo predominantemente no amnesico. En dichos estadios sumamente precoces, la perdida de volumen neuronal en el plano axial z = -12 mm se encuentra aun por debajo del umbral de deteccion morfometrica macroscopica, especialmente en escaneos provenientes de resonadores de 1,5 T de la cohorte ADNI-1 temprana con espesores de corte cercanos a 1,2 mm. Este hallazgo subraya la necesidad de incorporar biomarcadores moleculares de liquido cefalorraquideo o tecnicas de difusion DTI en casos con morfometria estructural limítrofe.

Asimismo, el compromiso dimensional 2.5D demuestra ser optimo frente al dilema clasico entre 2D y 3D en neuroimagen. Las adquisiciones clinicas de rutina frecuentemente presentan anisotropia espacial con espaciado intercorte mayor que la resolucion in-plane. Los filtros convolucionales tridimensionales isotropicos sufren de artefactos de interpolacion cuando se aplican sobre datos con anisotropia nativa, mientras que el triplete axial 2.5D explota la maxima fidelidad espacial en el plano canonico, preservando a la vez el gradiente axial adyacente (+- 1 mm) sin incurrir en la explosion cuadratica de parametros que aqueja a los modelos 3D densos.

Desde la optica de la inteligencia artificial explicable (XAI), el modulo de Attention Rollout (Figuras 6, 7 y 10) proporciona una validacion biologica independiente: la red neuronal focaliza su mayor densidad de atencion sobre el subiculum, las astas de Ammon (CA1-CA3) de la formacion hipocampal y la corteza entorrinal medial, zonas que coinciden milimetricamente con los estadios transentorrinales I y II del esquema histopatologico de Braak. Al prescindir de gradientes inestables en tiempo de prueba, Attention Rollout asegura una reproducibilidad determinista que fortalece la confianza del especialista medico en las predicciones del sistema.

10. Conclusiones y trabajo futuro

En esta investigacion se desarrollo, implemento y valido de manera exhaustiva un sistema integral para el diagnostico prodromico de la enfermedad de Alzheimer a partir de resonancia magnetica estructural, sustentado en la arquitectura Vision Transformer (ViT-B/16) adaptada a tensores axiales 2.5D. Los objetivos de investigacion establecidos se cumplieron satisfactoriamente en su totalidad:

• O1 (Protocolo y datos): Se estructuro un corpus curado de 1.200 escaneos ADNI/OASIS balanceados bajo el estandar PRISMA 2020, con particion estratificada estricta por sujeto que garantiza la ausencia total de fuga de datos.

• O2 (Modelado computacional): Se adapto ViT-B/16 con preprocesamiento axial z = -12 mm en MNI152 y normalizacion parenquimal, alcanzando 91,7 % de Exactitud global, 91,7 % de Exactitud Balanceada y Macro AUC de 0,982 en prueba ciega.

• O3 (Interpretabilidad): Se implemento Attention Rollout con ponderacion residual w = 0,5, demostrando que mas del 68 % de la masa de atencion

converge sobre estructuras hipocampales clinicamente congruentes.

• O4 (Optimizacion): Se compilo el pipeline mediante TorchScript JIT, reduciendo la latencia de inferencia en CPU a 498,2 ms (-14,9 %) con discrepancia numerica nula frente a PyTorch Eager (delta < 1e-7).

• O5 (Reproducibilidad): Se establecio una suite automatizada de 200 pruebas unitarias y de integracion con un 100 % de tasa de aprobacion continua.

La relevancia social e institucional del proyecto reside en su potencial democratizador: al posibilitar la clasificacion precoz de alta precision sobre hardware CPU estandar con un consumo de memoria pico de apenas 386 MB, el sistema se perfila como una herramienta viable para centros de atencion primaria y hospitales regionales en Colombia y America Latina que carecen de infraestructura computacional de supercomputo GPU o de acceso rutinario a biomarcadores PET de amiloide.

Como lineas de investigacion futura orientadas a la siguiente etapa (Seminario IV), se proyecta: (1) el reentrenamiento y calibracion probabilistica sobre volumenes NIfTI directos en cluster de GPU; (2) la extension hacia representaciones ortogonales triplanares acoplando cortes axiales, coronales y sagitales mediante fusion de atencion cruzada (Cross-Attention); y (3) la integracion multimodal de variables clinicas cuantitativas (tau fosforilada p-tau181 y genotipado APOE-e4).

11. Referencias

Abnar, S., & Zuidema, W. (2020). Quantifying attention flow in transformers. In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (pp. 4190-4197).

Chefer, H., Gur, S., & Wolf, L. (2021). Transformer interpretability beyond attention visualization. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (pp. 782-791).

Chen, J., et al. (2021). TransUNet: Transformers make strong encoders for medical image segmentation. arXiv preprint arXiv:2102.04306.

Cuingnet, R., et al. (2011). Automatic classification of patients with Alzheimer's disease from structural MRI: a comparison of ten methods using the ADNI database. NeuroImage, 56(2), 766-781.

Desikan, R. S., et al. (2006). An automated labeling system for subdividing the human cerebral cortex on MRI scans into gyral based regions of interest. NeuroImage, 31(3), 968-980.

Dosovitskiy, A., et al. (2021). An image is worth 16x16 words: Transformers for image recognition at scale. In International Conference on Learning Representations (ICLR 2021).

Fischl, B. (2012). FreeSurfer. NeuroImage, 62(2), 774-781.

Ghazi, M. M., et al. (2019). Training recurrent neural networks robust to incomplete data: Application to Alzheimer's disease progression modeling. Medical Image Analysis, 53, 39-46.

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (pp. 770-778).

Hosseini-Asl, E., et al. (2016). Alzheimer's disease diagnostics by adaptation of 3D deeply supervised adaptable convolutional network. IEEE Journal of Selected Topics in Signal Processing, 10(7), 1254-1265.

Jack, C. R., et al. (2008). The Alzheimer's Disease Neuroimaging Initiative (ADNI): MRI methods. Journal of Magnetic Resonance Imaging, 27(4), 685-691.

Jenkinson, M., et al. (2012). FSL. NeuroImage, 62(2), 782-790.

Kloppel, S., et al. (2008). Automatic classification of MR scans in Alzheimer's disease. Brain, 131(3), 681-689.

Lian, C., et al. (2018). Hierarchical fully convolutional network for joint atrophy localization and Alzheimer's disease diagnosis using structural MRI. IEEE Transactions on Pattern Analysis and Machine Intelligence, 42(4), 880-893.

Litjens, G., et al. (2017). A survey on deep learning in medical image analysis. Medical Image Analysis, 42, 60-88.

Marcus, D. S., et al. (2007). Open Access Series of Imaging Studies (OASIS): cross-sectional MRI data in young, middle aged, nondemented, and demented older adults. Journal of Cognitive Neuroscience, 19(9), 1498-1507.

Page, M. J., et al. (2021). The PRISMA 2020 statement: an updated guideline for reporting systematic reviews. BMJ, 372, n71.

Paszke, A., et al. (2019). PyTorch: An imperative style, high-performance deep learning library. In Advances in Neural Information Processing Systems (NeurIPS, pp. 8024-8035).

Selvaraju, R. R., et al. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. In IEEE International Conference on Computer Vision (pp. 618-626).

Simancas, J., & Sanchez, M. (2026). Deteccion prodromica de la enfermedad de Alzheimer mediante Vision Transformers aplicados a imagenes de resonancia magnetica estructural. Proyecto de Investigacion, Seminario III, Universidad del Magdalena.

Vaswani, A., et al. (2017). Attention is all you need. In Advances in Neural Information Processing Systems (NeurIPS, pp. 5998-6008).

Weiner, M. W., et al. (2012). The Alzheimer's Disease Neuroimaging Initiative: a review of papers published since its inception. Alzheimer's & Dementia, 8(1), S1-S68.

Yao, D., et al. (2023). A Swin Transformer-based deep learning framework for Alzheimer's disease diagnosis using structural MRI. Medical Physics, 50(4), 2358-2370.

Zhang, D., et al. (2021). Multi-modal deep learning for Alzheimer's disease diagnosis from 2.5D structural MRI with DenseNet. IEEE Access, 9, 101665-101676.

12. Apendice: Reproducibilidad, trazabilidad y codigo

Entorno de ejecucion y versiones estandarizadas:

Python >= 3.12 • torch == 2.14.0 • torchvision == 0.19.0 • nibabel == 5.4.2 • scikit-learn == 1.9.1 • reportlab == 5.0.1 • pytest == 9.1.1

Tabla 10. Trazabilidad de hitos (H1-H7) y entregables tecnicos (E1-E7) de Seminario III.

Hito	Semana	Entregable Tecnico	Estado
H1	S5	E1: Plan de datos y particion sin solapamiento	Aceptado
H2	S7	E2: Preprocesamiento y extraccion 2.5D	Aceptado
H3	S9	E3: Arquitectura ViT-B/16 y baseline	Aceptado
H4	S11	E4: Interpretabilidad Attention Rollout	Aceptado
H5	S13	E5: Sensibilidad, ruido y rotacion	Aceptado
H6	S15	E6: Pipeline integrado y TorchScript JIT	Aceptado
H7	S16	E7: Informe final, sustentacion y 200 tests	Aceptado

Secuencia automatizada para replicacion total:

1. Verificacion de datos y auditoria sin solapamiento:

```
python scripts/run_audit_dataset.py
```

2. Preprocesamiento canonico 2.5D (z = -12 mm MNI152):

```
python scripts/run_preprocessing.py
```

3. Entrenamiento del modelo ViT-B/16 (seed = 42, 50 epocas):

```
python scripts/run_training.py
```

4. Computo y trazado de mapas Attention Rollout (w = 0,5):

```
python scripts/run_attention_rollout.py
```

5. Compilacion y benchmark de portabilidad TorchScript (I9):

```
python scripts/benchmark_torchscript.py
```

6. Ejecucion de suite completa de pruebas (200 tests - I7):

```
pytest tests/ -q
```

Inventario de artefactos generados:

• Pesos optimos del modelo (PyTorch): models/vit_b16_best.pth

• Binario compilado portable (TorchScript JIT): models/vit_b16_torchscript.pt

• Matriz de trazabilidad de entregables e hitos: configs/reports/weekly_reports.json

• Suite de pruebas unitarias y de integracion: tests/test_s16_final_closure.py

• Documento academico formal compilado: docs/reports/Articulo_Final_Seminario_III.pdf

Descargo de responsabilidad etica y clinica (Riesgo R7)

El software y los modelos desarrollados en este proyecto representan herramientas de investigacion cientifica y soporte computacional (Clinical Decision Support System - CDSS). Bajo ninguna circunstancia deben utilizarse para la emision de diagnosticos medicos definitivos de forma autonoma ni para la prescripcion de intervenciones terapeuticas sin la supervision directa de profesionales medicos colegiados en neurologia o radiologia. Version de repositorio: alzheimer-vit-smri == 0.1.0.