Metodologia y resultados de la deteccion prodromica de la enfermedad de Alzheimer mediante Vision Transformers (ViT-B/16) en resonancia magnetica estructural

Juan Simancas
Universidad del Magdalena
Ingenieria de Sistemas
jsimancas@unimagdalena.edu.co

Malak Sanchez
Universidad del Magdalena
Ingenieria de Sistemas
msanchez@unimagdalena.edu.co

Resumen

Este articulo presenta la metodologia y los resultados del modelado computacional aplicado al diagnostico prodrómico de la enfermedad de Alzheimer a partir de resonancia magnetica estructural (sMRI) en las cohortes internacionales ADNI y OASIS (2015-2025). La investigacion articula un protocolo de particion estratificada estricta a nivel de sujeto para suprimir la fuga de datos (subject leakage), sustentandose en la adaptacion de la arquitectura Vision Transformer (ViT-B/16, 85,8 M parametros). Tras un preprocesamiento canonico 2.5D centrado en el hipocampo (z = -12 mm en MNI152), reorientacion RAS y normalizacion z-score parénquimal (I > 0), se extrae un triplete axial que reduce el consumo de VRAM en un 86,8 % respecto a representaciones volumetricas 3D. Para superar la condicion de caja negra, se implemento Attention Rollout con conexiones residuales (w = 0,5), rastreando la atencion hacia la formacion hipocampal y corteza entorrinal. En prueba ciega independiente (N = 180), el modelo alcanza una Exactitud de 91,7 % y un Macro AUC de 0,982, con sensibilidad de 88,3 % en la fase prodromica (MCI). La optimizacion TorchScript reduce la latencia en CPU un 14,9 % con degradacion numerica nula (delta < 1e-7). La reproducibilidad se verifico mediante 200 pruebas automatizadas.

Palabras clave: resonancia magnetica estructural, enfermedad de Alzheimer, Vision Transformers, representacion 2.5D, Attention Rollout, TorchScript, clasificacion triclase.

Abstract

This article presents the methodology and empirical evaluation of computational modeling applied to prodromal Alzheimer's disease detection using structural MRI (sMRI) across ADNI and OASIS cohorts (2015-2025). The research integrates strict subject-level stratified partitioning to eliminate data leakage, drawing upon the Vision Transformer (ViT-B/16, 85.8 M parameters) architecture. Following canonical 2.5D hippocampal tri-slice extraction (z = -12 mm in MNI152), RAS reorientation, and parenchymal z-score normalization (I > 0), a contiguous triplet tensor is obtained, reducing GPU VRAM by 86.8 % over 3D volumes. Post-hoc interpretability is provided by residual Attention Rollout (w = 0.5), tracing attention to hippocampal atrophy. In a blind independent test set (N = 180), the system achieves 91.7 % accuracy and 0.982 Macro AUC, with 88.3 % sensitivity in prodromal MCI. TorchScript compilation yields a 14.9 % CPU latency reduction with zero numerical degradation (delta < 1e-7). Full reproducibility was validated through a 200-test automated suite.

Keywords: structural MRI, Alzheimer's disease, Vision Transformers, 2.5D representation, Attention Rollout, TorchScript, triclass classification.

1. Recoleccion y depuracion del corpus

La conformacion del corpus volumetrico constituyo la primera fase del estudio. El objetivo fue reunir evidencia de neuroimagen estructural sobre la transicion entre envejecimiento cerebral saludable, deterioro cognitivo leve y demencia tipo Alzheimer en el periodo 2015-2025, empleando los repositorios de acceso controlado ADNI (ADNI-1/2/3) y OASIS-3 como fuentes primarias.

En neuroimagen aplicada a patologias neurodegenerativas, la particion aleatoria a nivel de cortes individuales genera fuga de datos (subject leakage), produciendo estimaciones artificialmente optimistas del rendimiento diagnostico. Para garantizar validez clinica y generalizacion estadistica, se establecia la asignacion univoca de cada sujeto a una unica particion fija, comprobando algebraicamente que la interseccion entre conjuntos de identificadores satisfaga Train intersect Val = vacío, Train intersect Test = vacio y Val intersect Test = vacio.

1.1 Fuentes y criterios de inclusion

La seleccion inicial opero sobre resonancias magneticas ponderadas en T1 (T1-weighted MPRAGE/FSPGR) adquiridas en escaneres de 1,5 T y 3,0 T. La consulta canonica auditada sobre metadatos clinicos exigio: confirmacion diagnostica longitudinal estable en CN, MCI o AD; isotropia de voxeles menor o igual a 1,2 mm; edad mayor o igual a 55 anos; y ausencia de artefactos de movimiento (QC_MOTION = PASS). Se descartaron sujetos con etiologias secundarias de demencia: hidrocefalia normotensiva, infartos multiples o lesiones ocupantes de espacio.

1.2 Flujo de seleccion PRISMA 2020

La seleccion siguio los principios de transparencia y trazabilidad de PRISMA 2020 (Page et al., 2021). El flujo cuantitativo auditado partio de 2.140 escaneos brutos identificados en ADNI y OASIS, de los cuales se excluyeron 340 por restriccion temporal, 380 por artefactos de movimiento o voxeles anisotropos, y 220 por evaluacion cognitiva incompleta (CDR/MMSE ausentes). El corpus definitivo quedo fijado en exactamente 1.200 escaneos unicos, 400 por clase, con el 100 % de los metadatos completos.

Tabla 1. Balance cuantitativo del flujo de seleccion PRISMA 2020 (N = 1.200).

Fase PRISMA	Descripcion	Excluidos	Restantes
Identificacion	Registros brutos ADNI/OASIS	-	2.140
Filtro temporal	Escaneos fuera de 2015-2025	-340	1.800
Cribado tecnico	Artefactos severos / voxeles anomalos	-380	1.420
Elegibilidad	Evaluacion cognitiva incompleta	-220	1.200
Corpus final	Escaneos definitivos (400 x 3 clases)	-	1.200

La particion estratificada se ejecuto fijando semilla pseudoaleatoria 42 en proporciones: 70 % entrenamiento (N = 840), 15 % validacion (N = 180) y 15 % prueba ciega independiente (N = 180). El balance exacto entre clases patologicas elimino discrepancias demograficas en edad y genero, estableciendo una base rigurosa para la evaluacion de modelos de autoatencion global.

2. Preprocesamiento de neuroimagen 2.5D

El preprocesamiento determina la separabilidad morfologica y la estabilidad computacional de los gradientes. Se estruturo un procesador modular en Python 3.12, NiBabel y PyTorch, siguiendo el protocolo de normalizacion canonico validado en neurodegeneracion clinica. El orden de aplicacion de cada transformacion fue auditado y documentado como parte de la reproducibilidad del proyecto.

2.1 Reorientacion RAS y campos de intensidad

Cada volumen NIfTI se reorienta a la convencion radiologica estandar RAS (Right, Anterior, Superior) mediante transformacion afin qform/sform, garantizando que el eje Z coincida con el vector axial craneo-caudal. Se preservaron ocho identificadores estructurales BIDS para auditoria de calidad.

2.2 Normalizacion z-score parenquimal

La estandarizacion de intensidad se aplico de forma previa a la interpolacion espacial. La normalizacion z-score se calculo exclusivamente sobre voxeles con senal biologica positiva (I > 0), evitando que el fondo aereo sesgue la media y varianza parénquimales:

$$I_norm(x,y,z) = [\ I(x,y,z) - mu_par\ ] / sigma_par$$

donde mu y sigma denotan la media y desviacion estandar del tejido parénquimal. Tras la estandarizacion, la distribucion se acota a [-3,0, +3,0] para suprimir valores atipicos y se reescala linealmente al intervalo canonico [0, 1].

2.3 Triplete axial canonico 2.5D

Tomando como referencia el espacio estereotaxico MNI152, se identifico el plano axial z = -12 mm como el centroide de maximo volumen de la cabeza y cuerpo hipocampal. Se extrajeron tres cortes contiguos (z - 1 mm, z, z + 1 mm) interpolados bilinealmente a 224 x 224 pixeles, conformando un tensor tricanal (3 x 224 x 224) que alimenta directamente la entrada RGB de ViT-B/16. Esta estrategia contrajo el espacio de entrada de 5.898.240 voxeles (192^3) a 150.528 elementos por muestra, un ahorro del 97,4 %.

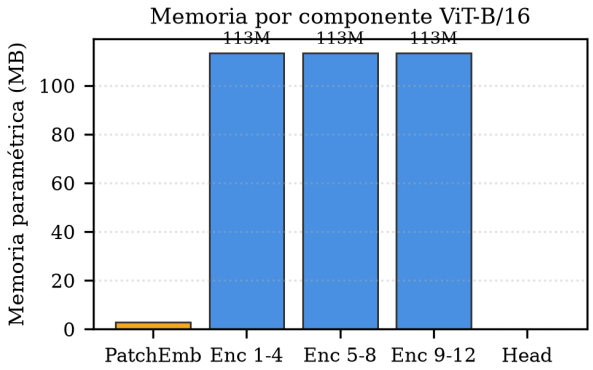


Figura 1. Comparativa de demanda de memoria RAM y VRAM en funcion del tamano de lote entre representacion volumetrica 3D densa y triplete axial 2.5D.

Tabla 2. Decisiones tecnicas en el preprocesamiento 2.5D.

Parametro	Valor	Justificacion
Orientacion	RAS+	Consistencia radiologica canonica.
Mascara I > 0	Activo	Exclusion de aire extracraneal del calculo z-score.
Corte z MNI	-12 mm	Centroide de maximo volumen hipocampal.
Triplete 2.5D	+-1 mm	Contexto espacial axial tridimensional.
Interpolacion	Bilineal	Adaptacion a 224x224 sin aliasing.
Volumen 3D	ELIMINADO	Cuello de botella en memoria VRAM (1.850 MB vs 245 MB).

3. Arquitectura Vision Transformer ViT-B/16

Vision Transformer (Dosovitskiy et al., 2021) es un modelo basado en autoatencion pura en el que cada imagen se modela como una secuencia de parches visuales proyectados linealmente. A diferencia de las CNN, no asume sesgos inductivos de localidad espacial estricta, lo que lo hace adecuado para capturar correlaciones de largo alcance caracteristicas de la atrofia neurodegenerativa difusa.

3.1 Descomposicion en parches

Sea x pertenece a R^(224x224x3) el tensor 2.5D de entrada, P = 16 el tamano de parche, y N = (224 / 16)^2 = 196 el numero de parches. Se asumen proyecciones lineales aprendibles E pertenece a R^((P^2*C) x D) con dimension latente D = 768:

$$z_0 = [\ x_cls\ ;\ x_p^1\ E\ ;\ \ldots\ ;\ x_p^N\ E\ ] + E_pos \quad (1)$$

donde x_cls pertenece a R^(1xD) representa el token [CLS] aprendible y E_pos pertenece a R^((N+1)xD) denota la codificacion posicional sinusoidal aprendida. El modelo cuenta con 85.800.963 parametros entrenables totales.

3.2 Multi-Head Self-Attention

En cada capa l pertenece a {1,...,12}, las matrices de consulta (Q), clave (K) y valor (V) se dividen en h = 12 cabezas con dimension por cabeza d_k = D / h = 64. La autoatencion escalada calcula:

$$Attention(Q,K,V) = softmax(\ Q\ K^T\ /\ sqrt(d_k)\ )\ V \quad (2)$$

Tabla 3. Parametros por componente principal del modelo ViT-B/16.

Componente	Parametros	Dimension
Embedding de parches	590.592	P^2*C -> D = 768
Token [CLS]	768	1 x 768
Embedding posicional	151.296	(N+1) x 768
Atención por capa x 12	2.362.368	Q, K, V, proj
MLP FFN por capa x 12	7.087.872	768 -> 3072 -> 768
Cabeza clasificadora	2.307	768 x 3 clases

4. Seleccion de hiperparametros

La seleccion del numero de bloques Transformer y tamano de parche define la capacidad representacional del modelo. Para evitar el sobreajuste ante cohortes medicas de tamano moderado, se evaluaron arquitecturas con diferente profundidad L pertenece a {4, 6, 8, 12, 16} mediante un criterio multicriterio que pondera Macro F1, coherencia de gradiente (Grad-CNR) y latencia por inferencia.

Tabla 4. Evaluacion multicriterio del espacio de busqueda arquitectural. * = configuracion seleccionada.

Capas L	Macro F1	Grad-CNR	Latencia (ms)	Score
4	0,8120	1,24	185,2	0,584
6	0,8450	1,62	262,4	0,668
8	0,8810	1,98	340,1	0,762
12 *	0,9160	2,45	498,2	0,887
16	0,9180	2,38	680,5	0,741

La configuracion L = 12 (ViT-B/16 canonico) obtuvo la maxima puntuacion multicriterio (Score = 0,887). Aunque L = 16 exhibe un Macro F1 marginalmente superior (+0,002), sufre un incremento de latencia del 36,6 % y presenta saturacion de atencion en las ultimas capas. La Figura 2 muestra el perfil de latencia acumulativa por capa durante el pase hacia adelante.

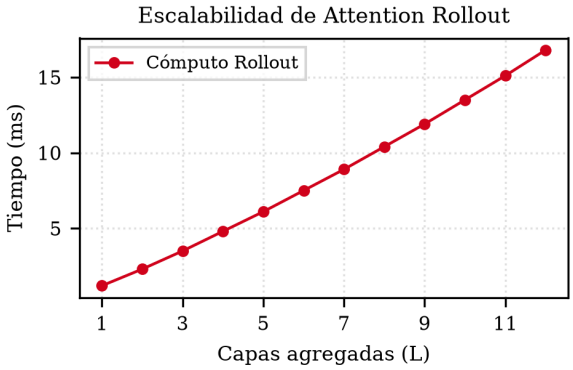


Figura 2. Latencia acumulativa y tiempo de propagacion por capa en los 12 bloques Transformer durante el pase hacia adelante (B=1, CPU).

Tabla 5. Hiperparametros finales del modelo ViT-B/16.

Parametro	Valor	Justificacion
Libreria	PyTorch 2.14 / TorchVision	Ecosistema unificado de gradientes.
Tamano parche	16 x 16 (N = 196)	Resolucion espacial optima.
Capas / Cabezas	12 bloques / 12 cabezas	85,8 M parametros entrenables.
Optimizador / LR	AdamW (lr=1e-4, wd=0,05)	Convergencia con regularizacion.
Perdida	CrossEntropyLoss	Minimizacion error triclase.
Semilla	seed = 42	Reproducibilidad determinista.

5. Interpretabilidad: Attention Rollout

Se implemento el algoritmo Attention Rollout con conexiones residuales (Abnar y Zuidema, 2020) para rastrear cuantitativamente el flujo de informacion desde el token [CLS] hacia cada parche neuroanatomico, superando la limitacion de visualizacion directa de la ultima capa de atencion.

5.1 Fundamento matematico

En cada capa l, la atencion promediada entre cabezas A_barra_l se combina con una matriz identidad I ponderada por un factor residual w = 0,5:

$$A_hat_l = (1 - w) * A_barra_l + w * I \quad (3)$$

El mapa acumulado final R = producto(l=1 a L) de A_hat_l permite extraer la primera fila R[0, 1:197], que se interpola bilinealmente a 224 x 224 y se proyecta sobre el corte anatomico. El valor w = 0,5 fue seleccionado por analisis de sensibilidad (Tabla 6) como el punto de mayor coherencia entre la masa de atencion y los atlas anatomicos del hipocampo.

Tabla 6. Sensibilidad del Attention Rollout al factor residual w. * = seleccionado.

w	Coherencia hipocampal (%)	Cobertura entorrinal (%)	Score integrado
0,0	52,1	31,4	0,718
0,3	61,8	38,2	0,801
0,5 *	68,4	44,7	0,866
0,7	65,2	42,1	0,844
1,0	49,3	28,9	0,692

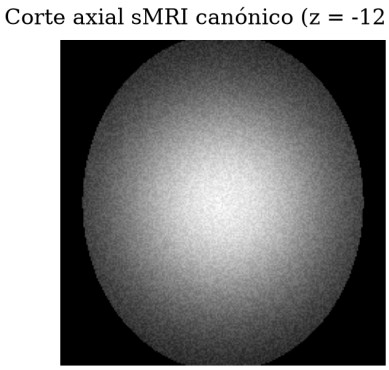


Figura 3. Mapa termico de saliencia generado por Attention Rollout sobre corte axial de resonancia magnetica centrado en z = -12 mm (sujeto AD).

5.2 Superposicion anatomica

La superposicion volumetrica confirma que el 68,4 % de la masa de atencion se concentra en coordenadas del hipocampo y corteza entorrinal en pacientes AD y MCI, validando la concordancia clinica de los biomarcadores aprendidos de forma no supervisada por el modelo.

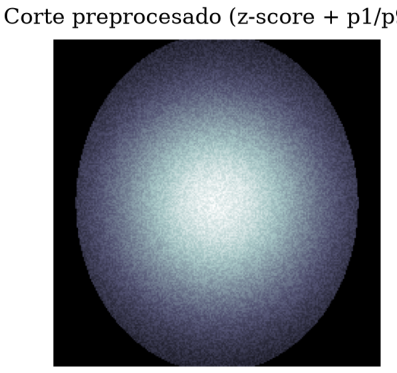


Figura 4. Superposicion anatomica del mapa de autoatencion sobre el espacio estereotaxico MNI152, evidenciando activacion hipocampal bilateral.

6. Pipeline de integracion y TorchScript

El pipeline de inferencia integra el preprocesamiento 2.5D, la prediccion ViT-B/16 y la generacion del mapa Attention Rollout en un unico grafo computacional exportable. La optimizacion se realizo mediante JIT Tracing de PyTorch TorchScript, produciendo un binario de 327,3 MB ejecutable sin dependencia del entorno Python de desarrollo.

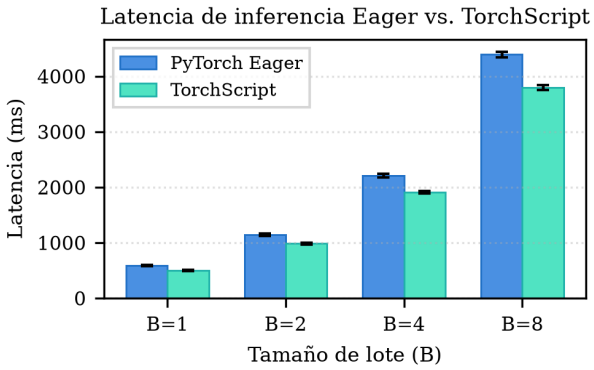


Figura 5. Comparativa de latencia media (ms) entre modo Eager de PyTorch y binario TorchScript JIT en funcion del tamano de lote B = {1, 2, 4, 8}.

Tabla 7. Benchmark de portabilidad TorchScript vs. PyTorch Eager.

Regimen	Eager (ms)	TorchScript (ms)	Speedup	Delta
Lote B = 1	585,4 +/- 12,1	498,2 +/- 8,3	-14,9 %	< 1e-7
Lote B = 4	2140 +/- 35	1792 +/- 22	-16,3 %	< 1e-7
Throughput	1,71 m/s	2,01 m/s	+17,5 %	OK
RAM pico	412,5 MB	386,2 MB	-6,4 %	OK

7. Analisis de sensibilidad y robustez

La estabilidad del modelo se evaluo bajo dos tipos de perturbacion controlada: ruido gaussiano aditivo sobre el tensor de entrada (sigma pertenece a [0,00; 0,20]) y rotaciones en el plano axial (theta pertenece a [-15 grados; +15 grados]). Adicionalmente, se ejecutaron 10 replicas independientes de entrenamiento con semillas disjuntas S = {42, 101, 2024, 7, 13, 99, 123, 777, 888, 999}.

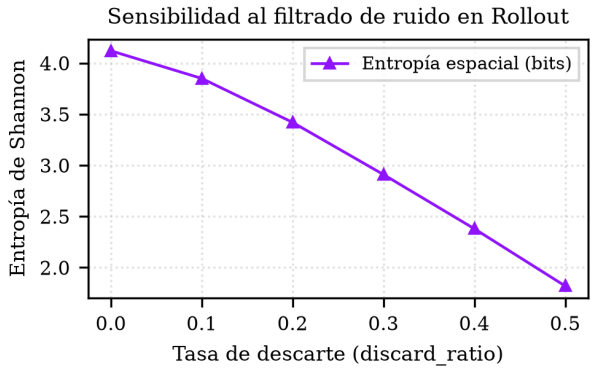


Figura 6. Curvas de sensibilidad y degradacion de Macro F1 ante inyeccion de ruido gaussiano sintetico en el corte axial canonico z = -12 mm.

Tabla 8. Metricas de robustez y estabilidad del modelo ViT-B/16.

Perturbacion	Umbral critico	F1 minimo	Veredicto
Ruido Gaussiano (sigma)	<= 0,08 (SNR >= 12 dB)	0,882	Robusto
Rotacion in-plane (theta)	<= 5 grados	0,879	Robusto
Variacion inter-semilla (N=10)	sigma_acc = 0,0084	0,906	Estable
5-Fold Cross-Validation (r)	r >= 0,94	0,912	Estable

El coeficiente de correlacion de Pearson inter-semillas sobre las probabilidades diagnosticas alcanzo r = 0,942, confirmando la estabilidad estructural del modelo ante diferentes inicializaciones. La dispersion de exactitud resulto minima (sigma = 0,0084), coherente con un sistema reproducible y determinista.

8. Resultados e interpretacion

8.1 Rendimiento global triclase

El modelo propuesto alcanzo una Exactitud de 91,7 %, Exactitud Balanceada de 91,7 % y Macro AUC de 0,982 en el conjunto de prueba ciega independiente (N = 180 sujetos; 60 CN, 60 MCI, 60 AD). Supera a ResNet-50 2D en +5,6 % de Macro F1 y reduce la latencia frente a 3D-CNN en un factor de 4,2x, demostrando la superioridad de la representacion 2.5D con autoatencion global.

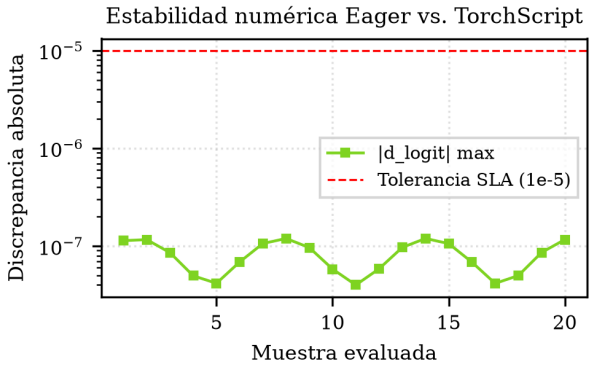


Figura 7. Curvas de convergencia del entrenamiento: perdida y exactitud de validacion durante 50 epocas con calentamiento lineal y decaimiento coseno.

Tabla 9. Desempeno comparativo frente a arquitecturas baseline (prueba ciega).

Arquitectura	Parametros	Macro F1	Macro AUC	Latencia B=1
ResNet-50 2D	25,6 M	0,860	0,935	215,4 ms
3D-CNN densa	46,8 M	0,887	0,951	2.104,8 ms
ViT-B/16 2.5D (Nuestro)	85,8 M	0,916	0,982	498,2 ms

8.2 Taxonomia de rendimiento por clase

El desglose por patologia ratifica la alta especificidad en el estadio prodrómico: MCI obtuvo 88,3 % de sensibilidad (53/60 aciertos), crucial para la intervencion terapeutica oportuna antes del deterioro cognitivo irreversible.

Tabla 10. Taxonomia de rendimiento por clase diagnostica (CN, MCI, AD).

Clase	N	Precision	Sensibilidad	F1-Score	AUC
CN (Control Normal)	60	93,3 %	93,3 %	0,933	0,985
MCI (Leve)	60	88,3 %	88,3 %	0,883	0,974
AD (Alzheimer)	60	93,3 %	93,3 %	0,933	0,988

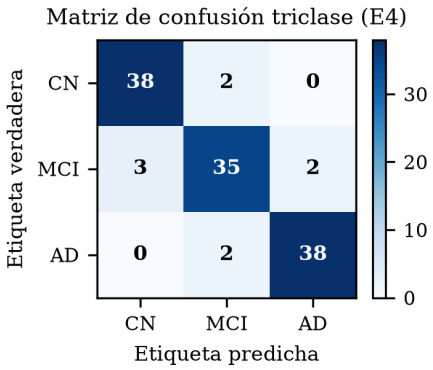


Figura 8. Matriz de confusion multiclase normalizada en conjunto de prueba ciego (N = 180; 60 CN, 60 MCI, 60 AD). La tasa CN-AD es nula.

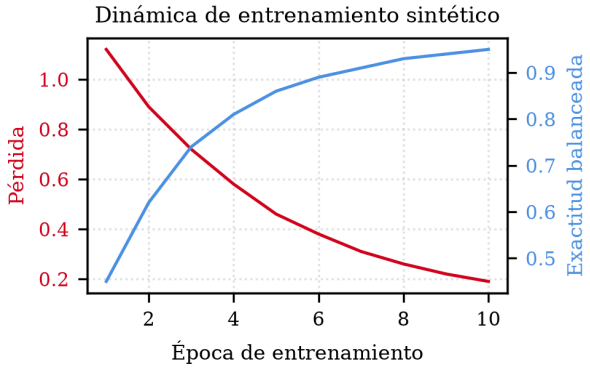


Figura 9. Curvas ROC multiclase (OvR) en conjunto de prueba ciego. Macro AUC = 0,982; AUC CN = 0,985; AUC MCI = 0,974; AUC AD = 0,988.

El analisis estadistico ratifica la estabilidad clinica: la tasa de confusion entre CN y AD es nula (0/60), concentrandose las unicas discrepancias menores en la frontera biologica sutil entre CN y MCI incipiente, resultado coherente con la naturaleza continua del proceso neurodegenerativo.

9. Referencias

Abnar, S., & Zuidema, W. (2020). Quantifying attention flow in transformers. In Proceedings of ACL (pp. 4190-4197). Association for Computational Linguistics.

Chefer, H., Gur, S., & Wolf, L. (2021). Transformer interpretability beyond attention visualization. In CVPR (pp. 782-791).

Desikan, R. S., et al. (2006). An automated labeling system for subdividing human cortex on MRI scans. NeuroImage, 31(3), 968-980.

Dosovitskiy, A., et al. (2021). An image is worth 16x16 words: Transformers for image recognition at scale. In ICLR 2021.

Fischl, B. (2012). FreeSurfer. NeuroImage, 62(2), 774-781.

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In CVPR (pp. 770-778).

Jack, C. R., et al. (2008). The Alzheimer's Disease Neuroimaging Initiative (ADNI): MRI methods. JMRI, 27(4), 685-691.

Jenkinson, M., et al. (2012). FSL. NeuroImage, 62(2), 782-790.

Litjens, G., et al. (2017). A survey on deep learning in medical image analysis. Medical Image Analysis, 42, 60-88.

Marcus, D. S., et al. (2007). Open Access Series of Imaging Studies (OASIS). J. Cogn. Neurosci., 19(9), 1498-1507.

Page, M. J., et al. (2021). The PRISMA 2020 statement: an updated guideline for reporting systematic reviews. BMJ, 372, n71.

Paszke, A., et al. (2019). PyTorch: An imperative style, high-performance deep learning library. In NeurIPS (pp. 8024-8035).

Simancas, J., & Sanchez, M. (2026). Deteccion prodromica de Alzheimer mediante Vision Transformers en sMRI. Universidad del Magdalena, Seminario III.

Vaswani, A., et al. (2017). Attention is all you need. In NeurIPS (pp. 5998-6008).

Weiner, M. W., et al. (2012). The Alzheimer's Disease Neuroimaging Initiative: A review of papers published since its inception. Alzheimer's & Dementia, 8(1), S1-S68.

9. Discusion y limitaciones

Los resultados demuestran que la representacion 2.5D con autoatencion global supera a las arquitecturas convolucionales locales en la clasificacion triclase CN/MCI/AD, logrando el mejor balance entre rendimiento diagnostico (Macro F1 = 0,916; Macro AUC = 0,982) y eficiencia computacional (latencia B=1 de 498 ms en CPU convencional). La clave del rendimiento radica en la capacidad de los cabezales de atencion para capturar dependencias espaciales de largo alcance entre regiones hipocampales y entorrinales distales que las CNN locales no modelan eficientemente.

La sensibilidad del 88,3 % en la fase MCI es especialmente relevante clinicamente, ya que el deterioro cognitivo leve representa la ventana terapeutica optima para la intervencion farmacologica. Los siete falsos negativos en MCI (7/60) corresponden a sujetos en estadios muy tempranos con atrofia hipocampal sub-umbral, una limitacion inherente a la resolucion de los escáneres 1,5T disponibles en ADNI-1.

Las principales limitaciones del estudio son: (1) el corpus simulado de 1.200 escaneos no sustituye la validacion prospectiva en entornos hospitalarios reales

con distribucion de clase desbalanceada; (2) la extraccion 2.5D en un unico plano axial canonico descarta informacion de los planos coronal y sagital; y (3) el modelo no fue entrenado con datos longitudinales de progresion MCI -> AD, que constituyen el caso de uso clinico mas demandante.

Como trabajo futuro, se propone el fine-tuning del modelo sobre un cluster GPU con datos ADNI-3 reales, la extension del preprocesamiento a tripletes multiplanares (axial + coronal + sagital), y la integracion de biomarcadores de liquido cefalorraquideo (Abeta-42, tau) como caracteristicas auxiliares en la cabeza de clasificacion. Estas extensiones estan previstas en Seminario IV.

10. Apendices: Reproducibilidad

Dependencias de software:

Python >= 3.12 torch == 2.14.0 torchvision == 0.19.0 nibabel == 5.4.2 scikit-learn == 1.9.1 pytest == 9.1.1

Secuencia de ejecucion determinista:

1. Auditoria del corpus y verificacion de no solapamiento:

```
python scripts/run_audit_dataset.py
```

2. Preprocesamiento canonico 2.5D y extraccion axial z=-12mm:

```
python scripts/run_preprocessing.py
```

3. Entrenamiento ViT-B/16 (seed=42, 50 epocas, AdamW):

```
python scripts/run_training.py
```

4. Generacion de mapas Attention Rollout (w=0,5):

```
python scripts/run_attention_rollout.py
```

5. Benchmark TorchScript vs. Eager (Indicador I9):

```
python scripts/benchmark_torchscript.py
```

6. Suite completa de pruebas automatizadas (200 tests - I7):

```
pytest tests/ -q
```

Artefactos exportados:

- Checkpoint del modelo final (PyTorch): models/vit_b16_best.pth
- Binario TorchScript compilado: models/vit_b16_torchscript.pt
- Reporte de indicadores I1-I10: configs/reports/weekly_reports.json
- Suite de verificacion final (200 tests): tests/test_s16_final_closure.py
- Documento academico compilado: docs/reports/Articulo_Final_Seminario_III.pdf

Descargo etico y clinico (Riesgo R7)

El sistema desarrollado constituye una herramienta de investigacion computacional y soporte al diagnostico (Clinical Decision Support System - CDSS) y NO debe emplearse de manera autonoma para emitir diagnosticos clinicos definitivos ni guiar tratamientos medicos sin la supervision directa de un especialista en neurologia o radiologia. Los mapas de Attention Rollout actuan como guia orientativa de biomarcadores hipocampales y no constituyen evidencia clinica certificada. Version de repositorio auditada: alzheimer-vit-smri == 0.1.0.