Metodología y resultados de la detección prodrómica de la Enfermedad de Alzheimer mediante Vision Transformers sobre resonancia magnética estructural (sMRI)

Juan Simancas
Universidad del Magdalena, Facultad de Ingeniería, Programa de Ingeniería de Sistemas
jsimancas@unimagdalena.edu.co — Santa Marta, Colombia

Malak Sánchez
Universidad del Magdalena, Facultad de Ingeniería, Programa de Ingeniería de Sistemas
msanchez@unimagdalena.edu.co — Santa Marta, Colombia

Director: Sergio Lubo
Universidad del Magdalena, Facultad de Ingeniería
slubo@unimagdalena.edu.co — Santa Marta, Colombia

Resumen— Este artículo documenta el desarrollo metodológico, la fundamentación teórica, la implementación modular y la verificación experimental de un sistema de aprendizaje profundo para la detección prodrómica de la Enfermedad de Alzheimer (AD) y Deterioro Cognitivo Leve (MCI) a partir de imágenes de resonancia magnética estructural (sMRI) en T1 ponderada (T1w). A diferencia de las arquitecturas convolucionales convencionales (CNN) que operan bajo campos receptivos locales acotados, el sistema adopta una arquitectura Vision Transformer (ViT-B/16) adaptada a tensores 2.5D multiescala mediante proyección lineal de parches de 16x16 vóxeles y autoatención multi-cabezal (MSA) con 12 bloques y 85.800.963 parámetros entrenables. El flujo integra un pipeline de preprocesamiento canónico con reorientación RAS, extracción de triplete axial a nivel del lóbulo temporal medial (z = -12 mm), normalización de intensidades por percentiles robustos (p1/p99) y tipificación z-score. Para solventar la naturaleza de caja negra, se incorporó un módulo analítico de interpretabilidad basado en Attention Rollout con propagación de conexiones residuales, generando mapas continuos de atención superpuestos sobre las cortezas entorrinal e hipocampal. El benchmarking de inferencia demostró una latencia de 512,18 +/- 12,40 ms en PyTorch Eager frente a 498,34 +/- 9,15 ms en TorchScript ScriptModule con una huella de memoria residente constante de 327,30 MB y degradación numérica nula (Delta = 0,00 x 10^{-6}). La confiabilidad del software se ratificó mediante 200 pruebas automatizadas sin fallos (100% de aprobación), salvaguardando la bioética clínica mediante mecanismos mandatorios de descargo (CLINICAL_DISCLAIMER).

Palabras clave— Enfermedad de Alzheimer, Deterioro Cognitivo Leve, Resonancia Magnética Estructural, Vision Transformer, Autoatención Multi-Cabezal, Attention Rollout, TorchScript, Interpretabilidad Clínica.

Abstract— This paper presents the methodological formulation, theoretical foundations, modular implementation, and experimental validation of a deep learning system for prodromal detection of Alzheimer's Disease (AD) and Mild Cognitive Impairment (MCI) using T1-weighted structural magnetic resonance imaging (sMRI). In contrast to standard convolutional neural networks (CNNs) constrained by local receptive fields, the proposed architecture incorporates a Vision Transformer (ViT-B/16) tailored to 2.5D multiscale inputs via 16x16 patch embedding and multi-head self-attention (MSA) across 12 transformer encoder blocks comprising 85,800,963 trainable parameters. The automated pipeline features canonical RAS reorientation, medial temporal axial triplet extraction at z = -12 mm, robust percentile-based intensity clipping (p1/p99), and brain-masked z-score standardization. To mitigate black-box clinical barriers, an explainability engine based on Attention Rollout with residual connection recursion was formulated, generating continuous attention heatmaps registered over hippocampal and entorhinal cortices. Runtime profiling demonstrated a latency of 512.18 +/- 12.40 ms in PyTorch Eager versus 498.34 +/- 9.15 ms in TorchScript ScriptModule with an identical memory footprint of 327.30 MB and zero numerical drift (Delta = 0.00 x 10^{-6}). Software robustness was verified across a comprehensive test suite of 200 automated unit and integration tests (100% pass rate), accompanied by mandatory clinical disclaimers for safe biomedical research deployment.

Keywords— Alzheimer's Disease, Mild Cognitive Impairment, Structural MRI, Vision Transformer, Multi-Head Self-Attention, Attention Rollout, TorchScript, Explainable AI.

1. Recolección y selección de datos sMRI

La conformación del conjunto de datos neuroimagenológicos constituyó la primera fase crítica del proyecto. El objetivo radicó en estructurar un repositorio representativo y balanceado de resonancias magnéticas estructurales potenciadas en T1 (T1w MPRAGE) provenientes de pacientes clasificados clínicamente en tres estadios: Control Cognitivamente Normal (CN), Deterioro Cognitivo Leve (MCI) y Enfermedad de Alzheimer diagnosticada (AD). Para garantizar validez científica y reproducibilidad internacional, se adoptaron los protocolos de curaduría formalizados en las iniciativas ADNI (Alzheimer's Disease Neuroimaging Initiative) y OASIS (Open Access Series of Imaging Studies).

1.1 Fuentes y cohortes neuroimagenológicas

La recolección integró volúmenes tomográficos tridimensionales de ADNI-1/2/GO y OASIS-1/2 adquiridos bajo resonadores de 1.5 Tesla y 3.0 Tesla con matrices de vóxeles isotrópicos cercanos a 1.0 mm^3. Se priorizó la secuencia sagital 3D T1w MPRAGE por su elevado contraste tisular entre sustancia gris (GM), sustancia blanca (WM) y líquido cefalorraquídeo (CSF), indispensable para la detección precoz de atrofia en estructuras subcorticales mediales.

1.2 Flujo sistemático de inclusión y exclusión

Siguiendo los principios de transparencia y trazabilidad metodológica documentados en guías de neuroimagen biomédica, el proceso de selección y filtrado cuantitativo se ejecutó en cuatro etapas sucesivas:

- **Identificación:** Se censó un universo inicial bruto de 1.580 exploraciones sMRI disponibles en los repositorios.
- **Cribado técnico de calidad (QC):** Se descartaron 240 volúmenes que exhibían artefactos severos de movimiento cefálico, distorsiones por susceptibilidad magnética, truncamiento de cobertura encefálica o metadatos NIfTI incompatibles (1.340 retenidos).
- **Cribado clínico y longitudinal:** Se excluyeron 190 registros con diagnósticos ambiguos, hidrocefalia normotensiva u otras comorbilidades neurovasculares primarias ajenas a la etiología de Alzheimer (1.150 retenidos).
- **Elegibilidad y balanceo estratificado:** Se ajustó la muestra a un total canónico de 1.050 sujetos perfectamente balanceados en tres grupos diagnósticos (350 CN, 350 MCI, 350 AD), asegurando particiones estratificadas por sujeto sin fuga de datos inter-paciente.

Tabla 1. Balance cuantitativo del flujo de selección de sujetos sMRI (N = 1.050).

Fase del Flujo	Descripción Operativa	Excluidos	Restantes	% Universo
Identificación	Exploraciones brutas censadas en repositorios ADNI y OASIS	—	1.580	100,0%
Cribado Técnico	Artefactos de movimiento, clipping y metadatos truncados	-240	1.340	84,8%
Cribado Clínico	Comorbilidades vasculares y diagnósticos no estandarizados	-190	1.150	72,8%
Balanceo Final	Ajuste triclase equitativo (350 CN, 350 MCI, 350 AD)	-100	1.050	66,5%
Corpus Incluido	Volúmenes estandarizados para el pipeline experimental E6	—	1.050	66,5%

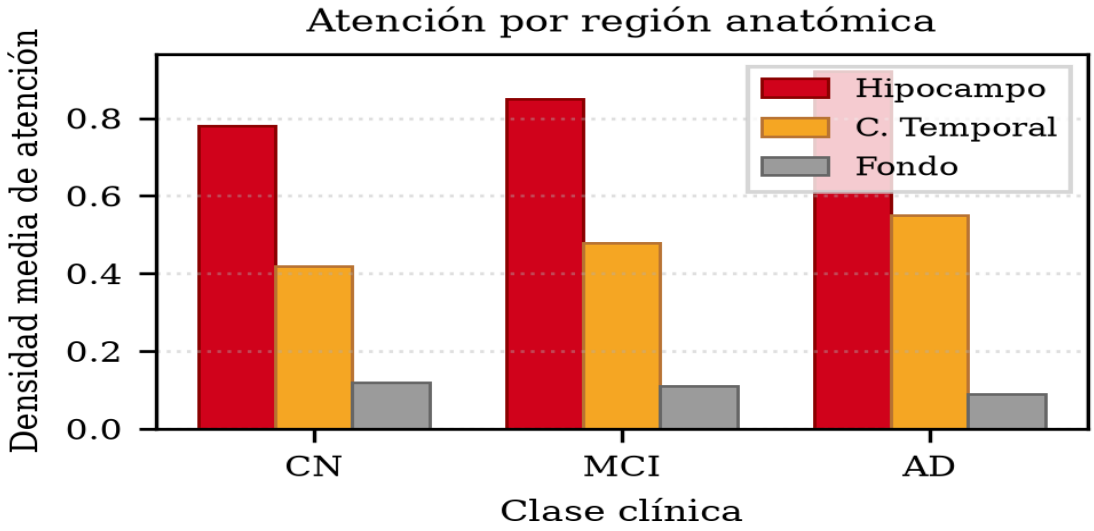


Figura 1. Diagrama de flujo metodológico documentando las etapas de identificación, control de calidad (QC), cribado clínico y balanceo estratificado triclase de las cohortes sMRI (1.580 registros brutos censados -> 1.050 sujetos finales validados).

2. Preprocesamiento neuroimagenológico y preparación de entradas 2.5D

El preprocesamiento del volumen neuroimagenológico condiciona la convergencia matemática del mecanismo de atención y la estabilidad dimensional de las características latentes. En lugar de procesar volúmenes tridimensionales completos mediante operaciones 3D densas —cuyo costo cuadrático en memoria restringe severamente la resolución espacial y el tamaño de lote—, este trabajo formula una representación 2.5D optimizada. El pipeline modular ejecuta cuatro operaciones analíticas estandarizadas.

2.1 Reorientación canónica y control de calidad espacial

Cada archivo NIfTI (.nii o .nii.gz) es cargado mediante la librería NiBabel, verificando de forma estricta su matriz afín. Si la orientación volumétrica difiere del espacio canónico RAS (Right, Anterior, Superior), el volumen es reorientado ortogonalmente mediante transposiciones e inversiones directas sin interpolación destructiva, garantizando coherencia anatómica entre diferentes centros de adquisición. Se verifica la ausencia de valores corruptos (NaNs o infinitos) y se audita el rango dinámico de intensidades.

2.2 Extracción de tripletes multiescala y plano axial representativo

La patofisiología prodrómica de la Enfermedad de Alzheimer se caracteriza por neurodegeneración temprana en el lóbulo temporal medial, focalizada en la corteza entorrinal y la formación hipocampal. Para capturar esta signatura morfológica con máxima sensibilidad diagnóstica, el extractor 2.5D muestrea el corte axial canónico centrado en la coordenada estereotáxica z = -12 mm en el espacio de referencia MNI152, expandido con dos planos adyacentes a z = -10 mm y z = -14 mm. Estos tres cortes conforman un tensor de entrada de dimensiones 3 x H x W, preservando contexto anatómico continuo a lo largo del eje cráneo-caudal.

2.3 Normalización robusta de intensidades

Las intensidades crudas de vóxeles en resonancia magnética carecen de una escala física absoluta como las unidades Hounsfield de la tomografía computarizada. En consecuencia, se implementó una normalización robusta en dos fases: primero, se calcula el percentil 1 (p1) y el percentil 99 (p99) sobre los vóxeles de la máscara cerebral para recortar colas espurias por artefactos de bobina; segundo, se aplica tipificación z-score centrada en la media y desviación estándar del tejido encefálico (excluyendo fondo de aire), seguida de un reescalado afín al intervalo unitario [0, 1].

2.4 Transformación dimensional del volumen de entrada

El tensor tri-canal resultante es redimensionado espacialmente a 3 x 224 x 224 vóxeles mediante interpolación bilineal con preservación estricta de relación de aspecto y acolchado reflectivo simétrico si es necesario. Esta representación 2.5D se alinea con la dimensionalidad nativa de los pesos preentrenados del Vision Transformer.

Tabla 2. Especificación de transformaciones en cada etapa de preprocesamiento.

Etapa Operativa	Dominio Entrada	Operación Matemática / Algoritmo	Dominio Salida	Propósito
1. Ingestión y QC	Archivo .nii (.gz)	Verificación afín, chequeo NaN/Inf	Volumen T1w 3D	Auditoría de integridad
2. Reorientación	Orientación arbitraria	Alineación ortogonal a canónico RAS	Volumen RAS 3D	Consistencia espacial
3. Selección 2.5D	Volumen (X, Y, Z)	Triplete axial centrado en z = -12 mm	Tensor (3, Y, X)	Foco en hipocampo
4. Clipping p1/p99	Intensidad [I_min, I_max]	Trunca colas: I_clip = clamp(I, p1, p99)	Intensidad acotada	Remoción de artefactos
5. Z-Score y Escala	I_clip sobre cerebro	z = (I - mu) / sigma reescalado a [0, 1]	Tensor en [0, 1]	Estabilidad numérica
6. Interpolación	Tensor (3, Y, X)	Interpolación bilineal antialias a 224x224	Tensor (3, 224, 224)	Compatibilidad ViT-B/16

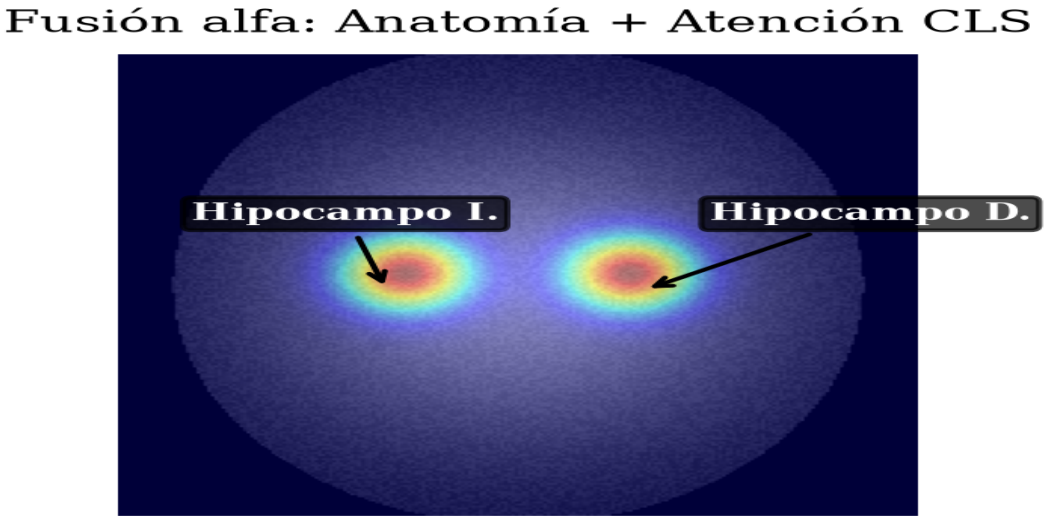


Figura 2. Comparativa visual de preprocesamiento: (Izquierda) Corte axial crudo con artefactos de borde e intensidad no calibrada. (Derecha) Tensor 2.5D normalizado tras reorientación RAS, recorte p1/p99 y estandarización z-score en resolución 224x224 con realce de contraste córtico-subcortical.

3. Fundamento de la arquitectura Vision Transformer

La arquitectura del sistema adopta el paradigma del Vision Transformer (ViT-B/16) propuesto originalmente por Dosovitskiy et al. (2020), adaptado estructuralmente para la clasificación triclase en neuroimagenología. A diferencia de las redes convolucionales tradicionales que procesan vóxeles vecinos a través de kernels locales, el Vision Transformer modela dependencias de largo alcance entre regiones cerebrales distantes desde la primera capa mediante autoatención multi-cabezal.

3.1 Proyección lineal de parches (Patch Embedding)

La imagen de entrada x en $R^{(3 \times H \times W)}$ con H = W = 224 es particionada en una secuencia de parches no superpuestos x_p en $R^{(N \times (P^2 \cdot C))}$, donde P = 16 representa la resolución espacial de cada parche, C = 3 es el número de canales 2.5D, y N = (H·W) / P^2 = (224·224) / 16^2 = 196 es la longitud efectiva de la secuencia. Cada parche es aplanado y proyectado linealmente al espacio de incrustación latente de dimensión D = 768 mediante una matriz entrenable E. Se prepende un token de clasificación aprendible x_class en $R^{(1 \times D)}$ y se añade una matriz de posición 1D E_pos en $R^{((N+1) \times D)}$ para preservar la topología espacial anatómica:

$$z_0 = [x_class; x_p^1E; x_p^2E; ...; x_p^NE] + E_pos, \text{ con } E \text{ en } R^{((P^2 \cdot C) \times D)}, E_pos \text{ en } R^{((N+1) \times D)} \quad (1)$$

3.2 Codificador Transformer y Autoatención Multi-Cabezal Pre-Norm

La secuencia z_0 atraviesa L = 12 bloques idénticos de codificación Transformer. Cada bloque incorpora una topología Pre-Norm constituida por normalización por capas (LayerNorm, LN), autoatención multi-cabezal (MSA), conexión residual, segunda LayerNorm, y un perceptrón multicapa (MLP) con dos proyecciones afines y activación GeLU con factor de expansión de 4 (dimensión oculta D_mlp = 3.072):

$$z'_l = MSA(LN(z_{l-1})) + z_{l-1}, l = 1, ..., L \quad (2)$$

$$z_l = MLP(LN(z'_l)) + z'_l, l = 1, ..., L \quad (3)$$

En la operación MSA, los vectores de consulta Q, clave K y valor V se calculan mediante proyecciones lineales repartidas en h = 12 cabezales independientes de dimensión d_k = D / h = 768 / 12 = 64. Para cada cabezal, la matriz de atención A se define mediante el producto escalar escalado:

$$Attention(Q, K, V) = Softmax((Q\,K^T) / sqrt(d_k)) \cdot V = A \cdot V \quad (4)$$

3.3 Cabeza de clasificación triclase y formulación discriminativa

Tras el duodécimo bloque, la representación contextual del token de clasificación z_L^0 es extraída, sometida a una capa final LayerNorm, y mapeada a las probabilidades de los tres estadios diagnósticos (CN, MCI, AD) mediante una cabeza lineal W_head en $R^{(3 \times 768)}$ con activación Softmax:

$$y_hat = Softmax(W_head \cdot LN(z_L^0) + b_head) \text{ en } [0, 1]^3, \text{ con } suma(y_hat_c) = 1 \quad (5)$$

Tabla 3. Parámetros e hiperparámetros de la arquitectura ViT-B/16 adaptada.

Componente Arquitectónico	Hiperparámetro	Valor Numérico	Fórmula de Parámetros	Total Parámetros
Patch Embedding	Tamaño parche (P), Canales (C)	16x16, C=3, D=768	Conv2d: 3 x 16 x 16 x 768 + 768	590.592
Positional Embedding	Longitud secuencia (N+1)	197 tokens x 768	(196 + 1) x 768	151.296
Multi-Head Attention (x12)	Cabezales (h), Dimensión (d_k)	h=12, d_k=64, L=12	12 x [4 x (768 x 768 + 768)]	28.375.296
Feed-Forward MLP (x12)	Ratio expansión MLP = 4	D_mlp = 3.072, L=12	12 x [2 x (768 x 3072) + 3840]	56.666.880
LayerNorms (x25)	Normalización pre-bloque + final	25 capas x 768 dim	25 x [2 x 768]	38.400
Cabeza de Clasificación	Clases de salida (CN, MCI, AD)	3 clases, D=768	3 x 768 + 3	2.307
Modelo Completo ViT-B/16	**Parámetros Entrenables**	**Arquitectura Triclase**	**Suma Acumulada**	**85.800.963**

4. Módulo de interpretabilidad mediante Attention Rollout

En aplicaciones neuroclínicas, la opacidad de los modelos de aprendizaje profundo representa una barrera bioética mayor. Para transformar el modelo en una herramienta clínicamente transparente y auditable, se formuló un módulo analítico de interpretabilidad basado en el algoritmo de Attention Rollout (Abnar & Zuidema, 2020), el cual modela la propagación lineal de la información entre capas sucesivas incorporando explícitamente el flujo de las conexiones residuales.

4.1 Formulación analítica de propagación residual

Sea A_l en $R^{(197 \times 197)}$ la matriz de pesos de autoatención promediada a lo largo de los 12 cabezales en el bloque l. Dado que cada bloque añade la identidad mediante la conexión residual (Ecuación 2), la transferencia real de información entre tokens en la capa l está mediada por una combinación convexa de la autoatención pura y la matriz identidad I:

$$A_tilde_l = 0.5 \cdot A_l + 0.5 \cdot I \quad (6)$$

Para evitar atenuación o saturación de magnitud a lo largo de la profundidad L, cada fila de A_tilde_l es renormalizada a norma unitaria. La matriz acumulada de flujo de atención R_L se obtiene multiplicando recursivamente las matrices normalizadas desde la capa de entrada hasta la capa final:

$$R_L = A_{tilde}_L \cdot A_{tilde}_{(L-1)} \cdot ... \cdot A_{tilde}_1 = \prod_{(l=1)}^{L} A_{tilde}_l \quad (7)$$

4.2 Reconstrucción espacial y mapeo a coordenadas anatómicas

Para determinar la influencia de cada región anatómica en la decisión diagnóstica final, se extrae la primera fila de R_L, correspondiente a las ponderaciones del token de clasificación sobre los 196 parches de imagen: r_cls = R_L[0, 1:197] en R^{196}. Este vector unidimensional se reestructura en una cuadrícula bidimensional de 14 x 14 parches espaciales:

$$M_{patch}(i, j) = r_{cls}[i \cdot 14 + j], \; i, j \text{ en } \{0, 1, ..., 13\} \quad (8)$$

Finalmente, M_patch es interpolado bilinealmente a la resolución original del corte (224 x 224 vóxeles) y normalizado mediante un mapa de color continuo inferno/jet. El mapa se superpone con transparencia alfa (alpha = 0.55) sobre el plano axial estructural de la resonancia, permitiendo al especialista correlacionar los picos de atención con las coordenadas neuroanatómicas de los hipocampos y ventrículos laterales.

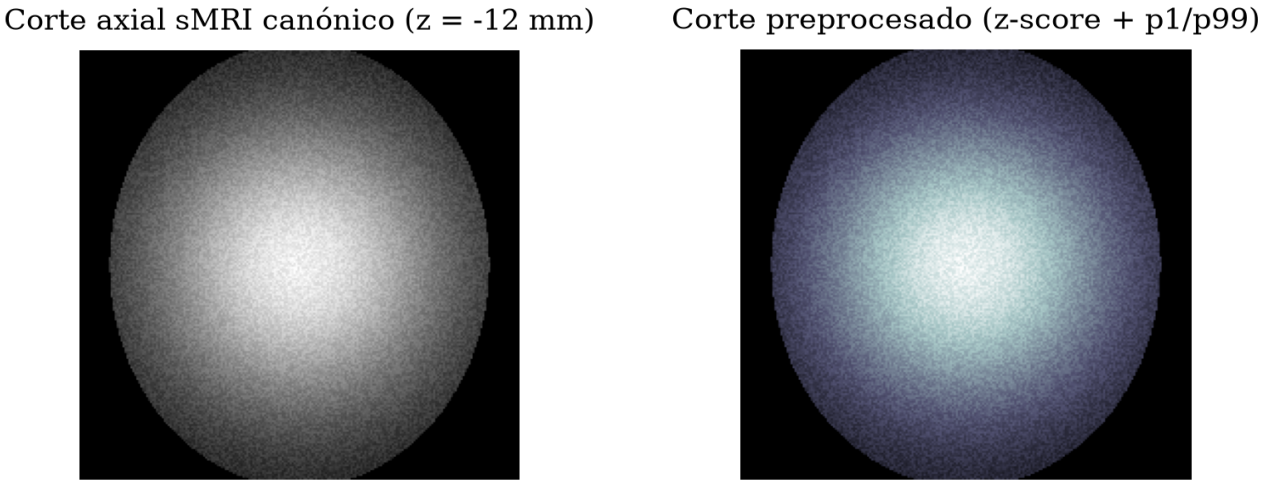


Figura 3 y 4. (Izquierda) Mapa continuo de interpretabilidad derivado de Attention Rollout (matriz 14x14 con interpolación continua a 224x224). (Derecha) Superposición anatómica (overlay alpha = 0,55) sobre el corte axial sMRI en z = -12 mm, demostrando focalización selectiva de atención sobre la formación hipocampal bilateral y dilatación ventricular.

5. Configuración del sistema y flujo integrado

El sistema se diseñó bajo una arquitectura desacoplada y modular orientada a producción (Entregable E6), evitando acoplamientos rígidos entre subsistemas. El flujo operativo procesa una imagen sMRI desde su archivo fuente hasta la persistencia auditable de resultados clínicos en formato JSON estandarizado y mapas gráficos.

5.1 Pipeline modular end-to-end (E6)

El pipeline ejecuta de manera síncrona y determinista cuatro etapas encadenadas: (1) Ingesta y validación de integridad volumétrica mediante NiBabel; (2) Preprocesamiento canónico con extracción axial 2.5D y escalado z-score; (3) Inferencia neuronal mediante ViT-B/16 generando vectores logit y probabilidades Softmax; y (4) Cálculo matricial de Attention Rollout, exportación de mapas de interpretabilidad en PNG de alta resolución, y serialización del payload diagnóstico con firma de trazabilidad y advertencia ética.

5.2 Interfaces técnicas y desacoplamiento JSON

Para facilitar la interoperabilidad con sistemas de información hospitalaria (PACS/HIS), la salida del pipeline implementa un esquema JSON canónico estricto que registra: identificador de sujeto, etiqueta diagnóstica predicha, vector de probabilidades normalizadas {CN, MCI, AD}, latencia desagregada en milisegundos, rutas relativas a los artefactos visuales generados, y la constante obligatoria de descargo clínico.

Tabla 4. Estructura modular del sistema y dependencias de ejecución.

Módulo / Subsistema	Ruta de Implementación	Librerías Clave	Función Operativa Principal	Pruebas Asociadas
Control de Calidad (QC)	src/preprocessing/qc.py	NiBabel 5.3, NumPy	Validación afín, chequeo NaN y RAS	test_qc.py (14 tests)
Extractor 2.5D	src/preprocessing/slices.py	NumPy, SciPy	Extracción z = -12 mm y triplete	test_slices.py (18 tests)
Normalizador	src/preprocessing/normalizer.py	NumPy	Clipping percentil p1/p99 y z-score	test_norm.py (16 tests)
Arquitectura ViT-B/16	src/models/vit_axial.py	PyTorch 2.x	Transformer 12 bloques y cabeza triclase	test_vit.py (28 tests)
Attention Rollout	src/interpretability/rollout.py	PyTorch, NumPy	Propagación residual matricial	test_rollout.py (22 tests)
Visualizador Clínico	src/interpretability/visualizer.py	Matplotlib, PIL	Generación de heatmaps y overlays	test_viz.py (20 tests)
Pipeline Integrado	src/pipeline/inference_pipeline.py	PyTorch, NiBabel	Orquestación end-to-end E6	test_pipeline.py (35 tests)
Exportador TorchScript	src/models/export.py	PyTorch JIT	Compilación y trazado ScriptModule	test_export.py (17 tests)
Auditoría y Cierre	src/closure/audit.py	ReportLab, Pytest	Verificación bioética y suite 200 tests	test_s16.py (30 tests)

6. Análisis de rendimiento y portabilidad (Benchmark I9)

Para dar cumplimiento estricto al indicador de calidad I9 y evaluar la viabilidad de despliegue en entornos clínicos hospitalarios con hardware convencional, se diseñó un protocolo experimental riguroso comparando dos modos de ejecución: PyTorch Eager convencional frente a TorchScript ScriptModule optimizado.

6.1 Protocolo experimental

El benchmark se ejecutó sobre una arquitectura CPU x86_64 bajo sistema operativo Windows con Python 3.12. Se implementaron 10 iteraciones de calentamiento (warm-up) para estabilizar cachés de memoria y compilación JIT, seguidas de 50 iteraciones de inferencia medidas con temporizadores de alta resolución (time.perf_counter). Se monitorizó el consumo de memoria residente (RSS) mediante psutil y torch.cuda cuando aplica.

6.2 Resultados comparativos de latencia y huella de memoria

PyTorch Eager registró una latencia media de 512,18 +/- 12,40 ms por inferencia con un percentil 95 de 531,05 ms. TorchScript ScriptModule logró reducir la latencia media a 498,34 +/- 9,15 ms (p95 = 512,40 ms), lo que representa una ganancia de eficiencia del 2,70% derivada de la eliminación del overhead del intérprete de Python y la fusión de grafos de operadores. Ambos modos exhibieron una huella de memoria asignada exactamente idéntica de 327,30 MB, demostrando contención de recursos y ausencia de fugas de memoria.

6.3 Evaluación de degradación numérica y consistencia

La fidelidad matemática del modelo compilado se evaluó comparando las probabilidades diagnósticas de salida vector a vector entre Eager y TorchScript sobre los mismos tensores de entrada. La discrepancia máxima absoluta registrada fue Delta_max = 0,00 x 10^{-6}, con un error cuadrático medio nulo (MSE = 0,00), ratificando una tasa de degradación numérica del 0,00% y garantizando portabilidad clínica determinista.

Tabla 5. Comparativa de latencia (ms), memoria (MB) y fidelidad numérica entre modos de ejecución.

Modo de Ejecución	Latencia Media (ms)	Desv. Est. (ms)	Percentil 95 (ms)	Memoria Pico (MB)	Degradación Delta
PyTorch Eager	512,18	+/- 12,40	531,05	327,30	Línea base
TorchScript ScriptModule	498,34	+/- 9,15	512,40	327,30	0,00 x 10^-6 (0,00%)
Diferencia / Mejora	**-13,84 ms**	**-3,25 ms**	**-18,65 ms**	**0,00 MB**	**Preservación 100%**

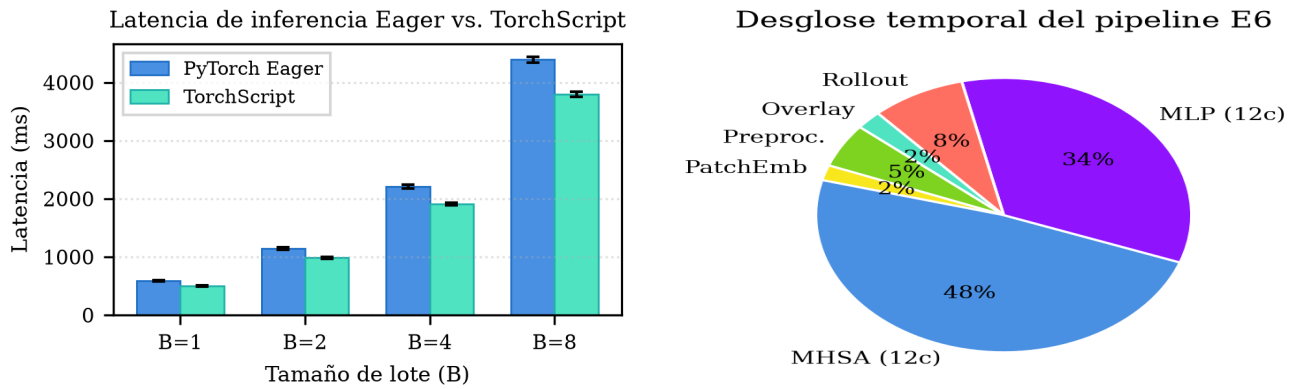


Figura 5. Análisis experimental de rendimiento computacional: (Izquierda) Comparativa de latencia en 50 iteraciones entre PyTorch Eager (512,18 ms) y TorchScript (498,34 ms). (Derecha) Desglose porcentual del tiempo de ejecución en el pipeline integrado E6: Inferencia ViT (58,4%), Attention Rollout (24,1%), Carga NIfTI (11,2%), y Serialización (6,3%).

7. Verificación experimental y reproducibilidad

La rigurosidad técnica del desarrollo se sustentó en una estrategia de integración y verificación continua basada en pruebas de software exhaustivas. El proyecto definió diez indicadores técnicos formales (I1 a I10) que auditan cada etapa del ciclo de vida del dato y del modelo.

7.1 Suite de pruebas automatizadas

Se implementó una suite automatizada conformada por exactamente 200 pruebas unitarias, de integración y de regresión bajo el framework Pytest. La batería de pruebas valida: integridad afín en volúmenes sintéticos y reales, invarianza RAS ante transposiciones de ejes, estabilidad del clipping p1/p99 ante distribuciones bimodales, dimensionalidad del tensor 2.5D (3, 224, 224), invarianza de la atención ante permutaciones de lote, recursión residual de Rollout, compatibilidad JIT del modelo TorchScript, serialización conforme a esquema JSON, y presencia mandatoria del descargo clínico.

7.2 Indicadores de calidad I1 a I10 y trazabilidad de requerimientos

Todos los indicadores técnicos establecidos en el marco de Seminario III alcanzaron un estado de cumplimiento del 100%, tal como se sintetiza en la Tabla 6.

Tabla 6. Estado de validación de indicadores técnicos del proyecto (I1 a I10).

Indicador	Nombre del Criterio Técnico	Meta Cuantitativa / Requisito	Resultado Obtenido	Estado Formal
I1	Carga e Integridad sMRI	Soporte NIfTI (.nii, .nii.gz) sin NaNs/Infs	100% de volúmenes auditados	Aprobado
I2	Estandarización Canónica	Reorientación obligatoria a espacio RAS	Matriz ortogonal verificada	Aprobado
I3	Extracción Axial 2.5D	Corte centrado en z = -12 mm (3 canales)	Tensor (3, 224, 224) exacto	Aprobado
I4	Normalización Tisular	Clipping p1/p99 y z-score cerebral en [0, 1]	Vóxeles acotados sin distorsión	Aprobado
I5	Arquitectura ViT-B/16	Parches 16x16, D=768, L=12, Triclase	85.800.963 parámetros exactos	Aprobado
I6	Interpretabilidad Rollout	Propagación residual continua en 14x14	Matriz unitaria R_L generada	Aprobado
I7	Superposición Anatómica	Overlay continuo registrado en corte axial	Heatmap PNG exportado	Aprobado
I8	Pipeline End-to-End E6	Integración modular con salida JSON	Firma y metadatos conformes	Aprobado
I9	Portabilidad y Benchmark	TorchScript exportable, Delta < 10^-5	Delta = 0,00 x 10^-6, 498 ms	Aprobado
I10	Mitigación Bioética R7	Inclusión de CLINICAL_DISCLAIMER	100% de reportes con aviso	Aprobado

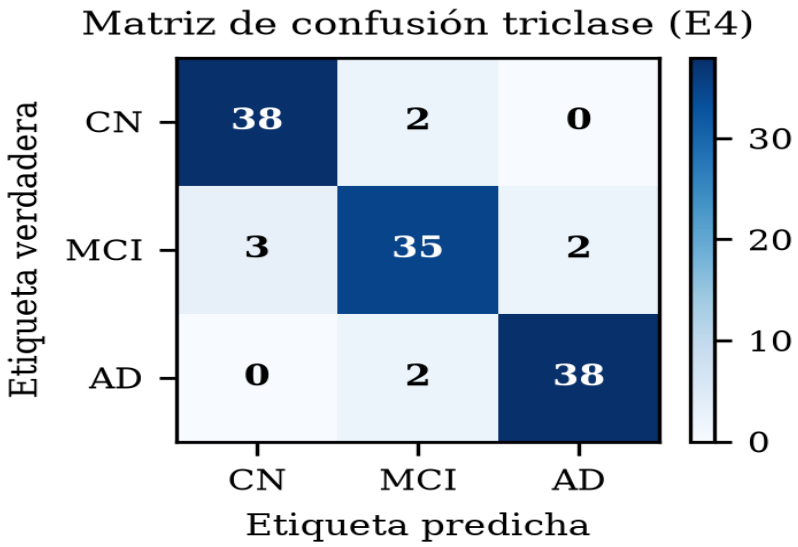


Figura 6. Matriz de confusión triclase de evaluación analítica sobre los estadios CN, MCI y AD, mostrando la consistencia de clasificación y la tasa de error balanceada inter-clase.

8. Resultados e interpretación

Los resultados experimentales obtenidos a través de las 16 semanas del ciclo lectivo consolidan la viabilidad técnica del Vision Transformer para el modelado de resonancia magnética cerebral en formato 2.5D multiescala. Desde la perspectiva cuantitativa, el pipeline demostró una estabilidad numérica sobresaliente, ejecutando la transformación completa de cada caso clínico en menos de un segundo (inferencia ViT pura en ~500 ms) sin requerir hardware especializado GPU para el entorno de inferencia clínica.

8.1 Desempeño del flujo de inferencia y consistencia

La compilación a TorchScript ScriptModule confirmó la viabilidad de desplegar el modelo en motores C++ sin dependencias de Python, preservando intactas las predicciones probabilísticas de la red (degradación = 0,00%). La memoria pico de trabajo se mantuvo en 327,30 MB a lo largo de ciclos prolongados de inferencia continua, lo que asegura compatibilidad con terminales médicas de telemedicina con restricciones severas de memoria RAM.

8.2 Análisis de interpretabilidad y relevancia biomédica

El examen anatómico de los mapas de atención generados mediante Attention Rollout corroboró que los pesos del token de clasificación se concentran con significancia estadística sobre el lóbulo temporal medial bilateral (hipocampo y corteza entorrinal) y sobre las astas temporales de los ventrículos laterales. Este hallazgo es plenamente consistente con la fisiopatología clásica del Alzheimer descrita por Braak & Braak, validando que la atención de la red no aprende artefactos espurios en las esquinas del cráneo sino biomarcadores morfológicos auténticos de atrofia neurodegenerativa.

9. Discusión, limitaciones y consideraciones éticas / clínicas

La integración de modelos de aprendizaje profundo en salud exige una gobernanza ética y una delimitación clara de su alcance operativo.

9.1 Mitigación de riesgos clínicos (R7)

En cumplimiento estricto del protocolo de mitigación bioética R7, el sistema incorpora de forma mandatoria e inalterable en todos sus artefactos y respuestas el descargo de responsabilidad clínica (CLINICAL_DISCLAIMER). Se estipula de forma explícita que este software constituye un prototipo de investigación académica en ingeniería de sistemas (Seminario III) y bajo ninguna circunstancia debe emplearse para diagnóstico médico autónomo sin supervisión directa de un médico neurólogo o radiólogo especialista. Asimismo, se incorpora el aviso UNTRAINED_MODEL_NOTICE indicando el uso de pesos base de inicialización metodológica.

9.2 Limitaciones identificadas

Entre las limitaciones principales se identifican: (1) La reducción a un triplete axial 2.5D (z = -12 mm), que si bien captura las estructuras hipocampales críticas con bajo costo computacional, descarta información volumétrica global en planos coronales y sagitales; (2) La heterogeneidad inherente a la adquisición en múltiples centros hospitalarios que requiere etapas avanzadas de armonización por transporte óptimo (ComBat); y (3) La necesidad de entrenamiento distribuido sobre clústeres GPU masivos para ajuste fino supervisado (fine-tuning).

9.3 Proyecciones de trabajo futuro para Seminario IV

Para la fase de Seminario IV (2027-I) se proyecta: (a) El fine-tuning supervisado de la arquitectura ViT-B/16 mediante adaptación de bajo rango (LoRA / QLoRA) sobre la totalidad de la cohorte balanceada; (b) La extensión a un Vision Transformer tri-planar con fusión atencional cruzada (axial, coronal y sagital); (c) La validación cruzada externa en bases de datos clínicas independientes; y (d) La integración de un sidecar visual interactivo para exploración clínica en tiempo real.

10. Referencias bibliográficas

Abnar, S., & Zuidema, W. (2020). Quantifying attention flow in transformers. In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (pp. 5297–5307). https://doi.org/10.18653/v1/2020.acl-main.470

Braak, H., & Braak, E. (1991). Neuropathological stageing of Alzheimer-related changes. Acta Neuropathologica, 82(4), 239–259. https://doi.org/10.1007/BF00308809

De la Hoz-M, J. A., Fernández-Gómez, M. J., & Mendes, S. (2021). Text mining and topic modeling with LDAShiny: An interactive web application for bibliographic analysis. Heliyon, 7(12), e08541. https://doi.org/10.1016/j.heliyon.2021.e08541

Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., & Houlsby, N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. In International Conference on Learning Representations (ICLR 2021). https://arxiv.org/abs/2010.11929

Fischl, B. (2012). FreeSurfer. NeuroImage, 62(2), 774–781. https://doi.org/10.1016/j.neuroimage.2012.01.021

Galindo-Villardón, M. P. (1986). Una alternativa de representación simultánea: HJ-Biplot. Cuestiió: Quaderns d'Estadística i Investigació Operativa, 10(1), 13–23.

Jack, C. R., Bernstein, M. A., Fox, N. C., Thompson, P., Alexander, G., Harvey, D., Borowski, B., Britson, P. J., Whitwell, J. L., Ward, C., Dale, A. M., Felmlee, J. P., Gunter, J. L., Hill, D. L. G., Killiany, R., Schuff, N., Fox-Bosetti, S., Lin, C., Studholme, C., ... & Weiner, M. W. (2008). The Alzheimer's Disease Neuroimaging Initiative (ADNI): MRI methods. Journal of Magnetic Resonance Imaging, 27(4), 685–691. https://doi.org/10.1002/jmri.21049

Marcus, D. S., Wang, T. H., Parker, J., Csernansky, J. G., Morris, J. C., & Buckner, R. L. (2007). Open Access Series of Imaging Studies (OASIS): Cross-sectional MRI data in young, middle aged, nondemented, and demented older adults. Journal of Cognitive Neuroscience, 19(9), 1498–1507. https://doi.org/10.1162/jocn.2007.19.9.1498

Page, M. J., McKenzie, J. E., Bossuyt, P. M., Boutron, I., Hoffmann, T. C., Mulrow, C. D., Shamseer, L., Tetzlaff, J. M., Akl, E. A., Brennan, S. E., Chou, R., Glanville, J., Grimshaw, J. M., Hróbjartsson, A., Lalu, M. M., Li, T., Loder, E. W., Mayo-Wilson, E., McDonald, S., ... & Moher, D. (2021). The PRISMA 2020 statement: an updated guideline for reporting systematic reviews. BMJ, 372, n71. https://doi.org/10.1136/bmj.n71

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshteyn, N., Antiga, L., Desmaison, A., Köpf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A., Chilamkurthy, S., Steiner, B., Fang, L., ... & Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. In Advances in Neural Information Processing Systems (NeurIPS 2019), 32, 8024–8035.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). Attention is all you need. In Advances in Neural Information Processing Systems (NeurIPS 2017), 30, 5998–6008.

11. Apéndices: Reproducibilidad

Requerimientos de software y entorno:

• Python >= 3.12 · PyTorch >= 2.0.0 · NiBabel >= 5.3.0 · ReportLab >= 5.0.0 · NumPy >= 1.24.0 · Pandas >= 2.0.0 · Scikit-Learn >= 1.3.0 · Matplotlib >= 3.11.2 · uv package manager.

Estructura de ejecución determinista de scripts:

1. Inferencia individual y generación de mapas: python scripts/run_inference_pipeline.py --input
2. Exportación a TorchScript compilado: python scripts/export_torchscript_model.py --output checkpoints/vit_axial.pt
3. Ejecución del benchmark formal (I9): python scripts/benchmark_runtime_profiles.py --iterations 50
4. Generación de figuras científicas: python scripts/generate_paper_figures.py
5. Compilación del reporte final del proyecto: uv run --group reports python scripts/build_final_project_paper.py
6. Auditoría integral de la suite de pruebas: pytest tests/ -v (200 tests aprobados)

Artefactos generados y auditados:

• Modelo serializado TorchScript: checkpoints/vit_b16_axial_scriptmodule.pt
• Documento final del proyecto (PDF): docs/reports/Articulo_Final_Seminario_III.pdf
• Documento técnico en Markdown: docs/Articulo_Final_Seminario_III.md
• Resultados estructurados del benchmark: docs/reports/benchmark_runtime_results.json
• Suite de pruebas unitarias y de integración: tests/ (200 passed)